




UNICAMP



Introdução à Prompts

Prof. Dr. André Gomes Regino
regino@unicamp.br

Agenda

01



Definição

02



**Prompt
Engineering**

03



Dados externos

04



Idioma

05



**Formatação de
Saída**

Objetivos

O Problema Central: Ambiguidade e Determinismo

Cenário

- Mesmo modelo, resultados diferentes.

A Causa Técnica

- LLMs são sistemas probabilísticos, não determinísticos.
- Pequenas variações na entrada (input)
- grandes variações na distribuição de probabilidade da saída (output)

O Problema Central: Ambiguidade e Determinismo

O Desafio

Como reduzir a variância e obter resultados consistentes

Resposta

Especificidade através da estrutura do prompt

Prompts

Prompt	Resposta Típica
<i>"Fale sobre diabetes"</i>	Texto genérico, "enciclopédico"
<i>"Liste 3 sintomas de diabetes tipo 2 em bullet points"</i>	Lista objetiva com 3 itens
<i>"Você é médico. Explique diabetes para um paciente de 70 anos, sem jargão, em 2 parágrafos"</i>	Texto acessível, empático, delimitado, contextualizado

Objetivos

- **Definir** o prompt como um conjunto de instruções programáveis
- **Estruturar** prompts (Contexto, Instrução, Dados, Formato)
- **Analisar** as limitações (Janela de Contexto e Custo de Tokens)
- **Implementar** formatação de saída (JSON)

Definição

se modelo == motor, então prompt == volante

Definição de Prompt

- Entrada enviada ao modelo
- **Formalmente:** É o conjunto de sinais de entrada utilizado para condicionar o modelo a gerar uma resposta específica



```
1 messages = [  
2     {"role": "system", "content": "Você é um assistente técnico  
    especializado em Python."},  
3     {"role": "user", "content": "Explique o que é um decorator em 3  
    linhas."}  
4 ]
```

Definição de Prompt

Um bom prompt define

- A **tarefa** que o modelo deve executar
- O **contexto** disponível para responder
- O **formato** esperado na resposta

```
1 prompt = f"""  
2 Classifique o sentimento do texto abaixo.  
3 Contexto: avaliação de produto em e-commerce.  
4 Responda apenas com: positivo, negativo ou neutro.  
5  
6 Texto: {avaliacao}  
7 """
```

Prompt "Engineering"

É Engenharia?

Prompt engineering NÃO é

- matemática pesada
- treino de modelo
- ciência exata com resultados garantidos

Prompt engineering É

- Processo iterativo: escreve → testa → mede → refina
- Design de instruções para controlar LLMs

"Engenharia" aqui significa: processo disciplinado e repetível

Melhorando Prompts

 Ruim:

Explique machine learning

 Melhor:

Você é um professor. Explique machine learning para iniciantes em 5 tópicos.

O que foi melhorado? Quais aspectos melhorar?

Componentes de um Bom Prompt



Uma estrutura completa garante resultados mais previsíveis e de melhor qualidade

Componentes

You are a medical assistant.

Based on the given patient symptoms, provide a possible diagnosis.

Read each of the symptoms and return a diagnosis with all symptoms.

I will provide one example. Complete the second.

Symptoms: Sudden fever, chills, muscle pain.

Diagnosis: Influenza.

Input:

Symptoms: {LIST_OF_SYMPTOMS}


Output:

Diagnosis: {DIAGNOSIS}

LEGENDA

- Papel
- Tarefa
- Exemplos
- Formato de entrada
- Formato de saída

Caso Real: Análise de Feedback de cliente



Refinando

Prompt Refinado

"Você é um assistente de atendimento ao cliente.

Tarefa: Analise o feedback abaixo e identifique o sentimento e os tópicos citados.

Formato de Saída: Retorne um objeto JSON.

Restrição: Seja conciso.

Feedback: 'O produto chegou atrasado, mas a qualidade é excelente.'"



Persona

Definição clara do papel do assistente.



Clareza

Tarefa e objetivos específicos definidos.



Técnica

Especificação do formato de saída JSON.

Resultado

```
1 {  
2   "sentimento": "Misto",  
3   "pontos_positivos": ["Qualidade excelente"],  
4   "pontos_negativos": ["Entrega atrasada"],  
5   "acao_recomendada": "Verificar logística de entrega"  
6 }
```

Este output pode ser consumido diretamente por uma função Python/JavaScript para alimentar um **dashboard** ou **banco de dados**

Dados Externos

Problema

LLMs são treinados com dados públicos

- até uma data de corte

Eles não sabem nada sobre

- Seus clientes
- Seu banco de dados
- Seus documentos internos
- Eventos recentes

A solução não é retreinar o modelo, é **inserir esses dados no prompt**

Injeção de Conteúdo

```
1 produto = db.query(''  
2         SELECT nome, preco, estoque  
3         FROM produtos  
4         WHERE id = ?'', produto_id)  
5  
6 prompt = f"""  
7 Você é um assistente de vendas. Responda sobre o produto abaixo.  
8  
9 Produto: {produto['nome']}  
10 Preço: R$ {produto['preco']}  
11 Disponível em estoque: {'Sim' if produto['estoque'] > 0 else 'Não'}  
12  
13 Pergunta do cliente: {pergunta_usuario}  
14 """
```

Desafios - Limite de Contexto

- Prompt + resposta têm limite
 - 8k, 32k, 128k, 1M tokens

Desafios – Limite de Contexto

"Lost in the middle"

- Mesmo com janelas grandes, **modelos perdem informações**
 - no meio do prompt
- LLMs recuperam melhor informações do **início e do fim** do contexto
- x tokens disponíveis
 - não significa que o modelo usa todos com igual qualidade

Desafios – Custos

Provedor	Modelo	Input*	Output*
OpenAI	GPT-5 / GPT-5.x	\$1,25 – \$2,50	\$10 – \$30
Anthropic	Claude Opus 4.6	\$5,00	\$25,00
Anthropic	Claude Sonnet 4.5	\$3,00	\$15,00
Google	Gemini 2.5 Pro / 3.x	\$1,25 – \$2,50	\$10 – \$12
Google	Gemini Flash-Lite	\$0,10	\$0,40
DeepSeek	DeepSeek V3.x	\$0,28	\$0,42

**Valor em dólares por 1 milhão de tokens*

Desafios – Custos

Cenário de Simulação

10k requisições (500 tokens input / 300 tokens output)

Total Input

5M tokens

Total Output

3M tokens

Impacto Mensal Estimado

\$50 (Gemini) **a \$1.800** (Claude)

Custo Estimado por Dia

Claude **\$60,00**

GPT **\$36,25**

DeepSeek **\$2,05**

Gemini **\$1,70**

Idioma

Posso escrever meus prompts em português?

Idioma importa?

Por que o inglês tende a ter melhor desempenho?

Idioma	% aproximado*
Inglês	~46–67%
Russo	~6–8%
Alemão	~5–6%
Português	~2–4%
Demais idiomas	Restante

**A composição dos dados de pré-treino em datasets comuns (Common Crawl, The Pile)*

Idioma importa?

1. *Of course.*
2. *Thank you for everything, a帕ia周末 Adventure Tryon G3 2006 1.8 8V is compatible.*
3. *No! It is not compative! with the Sandero 2013*
4. *I can not help in this case... I am a language model and do not have access to a list of existing cars.*
5. *Yes, it fits perfectly in your car. We are waiting for your purchase.*

Formatação de Saída

Saída Não Estruturada

Saída livre é imprevisível para sistemas

Prompt:

"O produto X é compatível com o sistema Y?"

Possíveis Respostas do LLM:

- "Sim, o produto X é compatível com o sistema Y."
- "Com base nas especificações, a compatibilidade é confirmada."
- "Compatível: Sim."
- "Não tenho certeza, mas acredito que sim."

Para um Humano:
Todas são aceitáveis

Para um Sistema (True/False):
Nenhuma funciona

Solução: JSON

```
1 prompt = """
2 Analise se o produto abaixo é compatível com o sistema informado.
3 Responda APENAS com um JSON válido, sem texto adicional, sem markdown.
4
5 Formato obrigatório:
6 {
7   "produto_compativel": true ou false,
8   "nivel_confianca": "alto" | "medio" | "baixo",
9   "explicacao": "motivo em uma frase"
10 }
11
12 Produto: Carregador USB-C 45W
13 Sistema: Dell Inspiron 15 3000 (requer 65W)
14 """
```

```
1 import json
2
3 resposta = modelo.gerar(prompt)
4 dados = json.loads(resposta)
5
6 if dados["produto_compativel"]:
7     print("Compatível ✅")
8 else:
9     print(f"Incompatível – {dados['explicacao']}")
```

Take-home Message



Estrutura é Rei

Use sempre Instrução + Contexto + Dados + Formato.



Especifique o Output

Não aceite texto livre; exija JSON, Markdown ou Listas.



Custo vs. Contexto

Otimize seu prompt para reduzir custos e latência.



Inglês para Lógica

Considere raciocínio em inglês para tarefas complexas, se necessário.

Mensagem Final

"LLMs não são inteligentes; são completadores de padrão excelentes. O seu prompt é o padrão que você quer ver completado."