




UNICAMP



Tipos de Prompts

Prof. Dr. André Gomes Regino

regino@unicamp.br

Agenda

01. Contexto

Problema: prompts simples nem sempre funcionam

02. Estratégia

Estratégias para melhorar a qualidade das saídas

03. Zero-shot

Instrução direta sem exemplos prévios

04. Few-shot

Aprendizado em contexto com poucos exemplos

05. Chain-of-thought

Encadeamento de raciocínio lógico

06. Prática

Comparação prática e resultados reais

07. Conclusão: Quando usar cada abordagem?

O Problema Central: Ambiguidade e Determinismo

Cenário

Prompts subespecificados geram variância nas respostas

Consequência

- Formato inconsistente.
- Falta de alinhamento com a tarefa específica
- Alucinação em tarefas complexas

Como restringir o espaço de busca da resposta usando apenas o prompt?

Objetivos

Objetivos

- **Compreender** os mecanismos de ativação de conhecimento em LLMs
- **Diferenciar** abordagens de prompting
- **Aplicar** Chain-of-Thought para resolver tarefas lógicas/matemáticas
- **Avaliar** o impacto no consumo de tokens e na latência da API

Visão Geral

Estratégias Principais



Zero-shot

Instrução direta, sem exemplos.

O modelo utiliza apenas o conhecimento adquirido durante o seu pré-treinamento.



Few-shot

Instrução acompanhada de exemplos.

Permite que o modelo aprenda e siga o padrão esperado através do contexto fornecido.



CoT

Raciocínio explícito passo a passo.

Solicita que o modelo decomponha o problema antes de fornecer a resposta final.

Dica: As estratégias não são exclusivas. É comum combinar **Few-shot** com **Chain-of-thought** para melhores resultados.

Intuição das Estratégias



Zero-shot

"Me ajuda a classificar isso?"



Few-shot

"Veja como classifiquei esses três casos. Agora faça o mesmo."



Chain-of-Thought

"Pensa em voz alta: quais critérios você usa?"

Lembre-se: A melhor estratégia depende da complexidade da tarefa e da qualidade do modelo.

Zero Shot

generalização pura

O que é Zero Shot

Capacidade do modelo de realizar uma tarefa **sem ter visto nenhum exemplo** específico dessa tarefa no prompt

Base Técnica

O modelo usa o conhecimento adquirido no treinamento em grande corpora

Quando funciona bem

- Tarefas onde o modelo já possui forte prior (conhecimento comum).
- Instruções que são autoexplicativas.

Exemplo - Triagem de Tickets de Suporte

Prompt de Entrada

Instrução: Classifique o ticket em uma das categorias: entrega, pagamento, produto, cancelamento ou outros.

Regra: Responda apenas com a categoria.

Ticket: "Meu boleto venceu ontem e não consigo gerar um novo."

Resposta do Modelo

pagamento

Exemplo - Extração

Prompt de Entrada

Instrução: Extraia o nome do produto e o problema relatado do texto abaixo.

Formato: Responda em JSON: {"produto": "...", "problema": "..."}

Texto: "O fone de ouvido Bluetooth que comprei para de conectar depois de 5 minutos."



Resposta do Modelo (JSON)

```
{  
  "produto": "fone de ouvido Bluetooth",  
  "problema": "desconecta após 5 minutos"  
}
```

Vantagens

Vantagem	Por que importa?
Simples de implementar	Nenhuma curadoria de exemplos necessária Útil em prototipagem rápida
Custo baixo	Menos tokens por requisição Menor custo em escala
Fácil de manter	Sem exemplos para atualizar quando a tarefa muda
Latência menor	Prompt menor Resposta mais rápida

Desvantagens

Ambiguidade

- "Resuma o texto" → modelo decide o tamanho, o tom e o nível de detalhe

Formato de saída imprevisível

- Mesmo pedindo JSON, o modelo pode adicionar texto explicativo antes ou depois

Falha em tarefas complexas

- Problemas com múltiplos passos lógicos geram respostas incompletas ou incorretas

Recomendações

Quando o Zero-Shot não é suficiente e você deve considerar o Few-Shot:



Classificação Customizada

Ideal para categorias que não são padronizadas ou comuns no treinamento do modelo.



Estilo ou Formato Específico

Quando a tarefa exige um tom de voz rigoroso ou um formato de dado muito técnico.



Raciocínio Encadeado

Essencial para diagnósticos, cálculos e problemas que requerem passos lógicos sequenciais.

Few Shot

Diminuindo a ambiguidade

O que é Few Shot

Fornecer **pares de entrada e saída** que demonstram o padrão esperado

O modelo usa esses exemplos para inferir

- O formato da resposta
- O critério de decisão
- O tom e nível de detalhe esperados

In-context Learning

Aprendizado que ocorre dentro do contexto da requisição

Estrutura do Prompt

INSTRUÇÃO BASE

[instrução]

Define a tarefa e as regras gerais

EXEMPLO 1

Entrada: [exemplo 1]

Saída: [resposta 1]

EXEMPLO 2

Entrada: [exemplo 2]

Saída: [resposta 2]

CASO REAL (INPUT)

Entrada: [caso real]

Saída: **Aguarda resposta do modelo**

O número de exemplos varia: 1-shot, 2-shot, 3-shot... Empiricamente, **3 a 5 exemplos** bem escolhidos cobrem a maioria dos casos.

Exemplo

Instrução: Classifique o ticket de suporte. Categorias: *entrega, pagamento, produto, cancelamento, outros*.

EXEMPLO 1

"O produto chegou errado, recebi um item diferente do pedido."

Categoria: produto

EXEMPLO 2

"Quero cancelar meu pedido feito hoje de manhã."

Categoria: cancelamento

EXEMPLO 3

"O código de rastreamento não atualiza há 3 dias."

Categoria: entrega

CASO REAL (INPUT)

"Meu boleto venceu ontem e não consigo gerar um novo."

Resposta do modelo: pagamento

Vantagens

Vantagem	Por que importa?
Maior precisão	Exemplos eliminam interpretações ambíguas da instrução
Controle de formato	O modelo replica o formato dos exemplos reduz necessidade de parsing
Reduz alucinações	Exemplos concretos ancoram o modelo no padrão desejado
Adaptação a domínios específicos	Sem retreino

BROWN, Tom et al. Language models are few-shot learners. **Advances in neural information processing systems**, v. 33, p. 1877-1901, 2020.

Limitações

- Explosão de Tokens
- Custo
- Viés de Recência: A ordem dos exemplos influencia o resultado. O modelo tende a repetir o padrão do último exemplo
- Curadoria Necessária: Exemplos ruins geram resultados ruins ("Garbage in, Garbage out")

Recomendações

- Use exemplos balanceados entre as categorias
- Inclua pelo menos 1 exemplo de cada classe
- Cubra casos limítrofes (borderline cases)

Zero Shot vs Few Shot

Métrica	Zero shot	Few shot
Precisão	Baixo	Maior
Acurácia	Variável	Maior
Curadoria	Menor	Necessária
Latência	Menor	Maior

Chain of Thought

Show me the ~~code~~ rationale

O que é Chain of Thought (CoT)?

Estratégia de prompting que instrui o modelo a produzir **etapas intermediárias de raciocínio** antes de gerar a resposta final.

Por que funciona?

Modelos de linguagem geram tokens sequencialmente.

Ao forçar o modelo a "*pensar em voz alta*", cada etapa serve como contexto para a próxima.

Exemplo de Gatilho

"Pense passo a passo antes de responder."

”

WEI, Jason et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, v. 35, p. 24824-24837, 2022.

Exemplo

Sem Chain of Thought (CoT)

PROMPT:

Uma empresa tem 47 funcionários e faturamento de R\$ 2,3M/ano. É elegível ao plano corporativo Plus (mín. 50 funcionários OU faturamento > R\$ 2M)?

RESPOSTA DO MODELO (ERRADA):

"Não, a empresa não é elegível."

Com Chain of Thought (CoT)

PROMPT (+ GATILHO):

... *Pense passo a passo antes de responder.*

RACIOCÍNIO INTERMEDIÁRIO:

1. **Funcionários:** 47 (mín. 50) → Não atende
2. **Faturamento:** R\$ 2,3M (mín. R\$ 2M) → Atende
3. **Regra (OU):** Basta um critério ser atendido.

RESPOSTA CORRETA:

"Elegível ao plano Plus."

O que muda com Chain-of-Thought

Sem CoT	Com CoT
Resposta direta	Raciocínio explícito + resposta final
Erros "silenciosos"	Erros "rastreadáveis"
Adequado para respostas simples	Necessário para problemas com múltiplos passos
Menor custo	Gera mais tokens de saída e maior latência

Comparativo

Quando Usar Cada um

Critério	Zero shot	Few shot	Chain of thought
Complexidade da tarefa	Baixa	Média	Alta
Formato de saída crítico	✗ Arriscado	✓ Recomendado	✓ Possível
Raciocínio multi-etapa	✗	✗	✓ Necessário
Custo por requisição	Baixo	Médio	Alto
Facilidade de implementação	Alta	Média	Média
Auditabilidade da resposta	✗	✗	✓

Quando Usar Cada um



Zero-shot

- Tarefa simples
- Bem definida
- Alto volume



Few-shot

- Formato específico
- Classificação customizada
- Consistência crítica



CoT

- Cálculo & Lógica
- Diagnóstico
- Múltiplos critérios



Combinados

- Tarefa complexa
- Formato rigoroso

Few-shot + CoT

Take Home Message



Fluxo de Decisão

Siga esta ordem para otimização:

- 1. Comece sempre com **zero-shot**.
- 2. Inconsistência de formato? Adicione exemplos (**few-shot**).
- 3. Erros de raciocínio? Use **Chain-of-Thought (CoT)**.



Decisão de Engenharia

- **Custo:** Tokens adicionais de exemplos e raciocínio.
- **Latência:** Maior tempo de processamento por saída.
- **Qualidade:** Precisão e consistência da resposta.

Trate como um componente de produção.