




UNICAMP



RAG: conceito

Prof. Dr. André Gomes Regino
regino@unicamp.br

Agenda

01. O problema dos LLMs isolados

Limitações de conhecimento e riscos de alucinação.

02. O que é RAG: definição e pipeline

O conceito de Retrieval-Augmented Generation.

03. Vantagens do RAG

Por que utilizar bases de dados externas com LLMs.

04. Quando usar (e quando não usar)

Critérios de decisão para implementação.

05. Aplicações reais em empresas

Casos de uso e impacto no ambiente corporativo.

O Problema dos LLMs Isolados

Conhecimento Congelado

O modelo não sabe o que ocorreu após o corte de treino. Ex: GPT-4 (Abr/23), Llama 3 (Dez/23).

Dados Privados Invisíveis

Documentos internos, bancos de dados corporativos e históricos de clientes permanecem inacessíveis.

Risco de Alucinação

Informações falsas mas plausíveis. Huang et al. (2023) estimam até 27% de erro em QA fechado.

Falta de Rastreabilidade

Respostas vêm de uma mistura opaca de dados de treino, dificultando o controle sobre a fonte real.

Consequência Prática:

"Em contextos críticos (jurídico, médico, financeiro), o uso de LLMs isolados representa um risco inaceitável."

Tentativa

```
# Tentativa ingênua: prompt gigante
with open("manual_empresa.txt") as f:
    documento = f.read() # 200 páginas → ~150.000 tokens
prompt = f"""
Contexto: {documento}
Pergunta: Qual é a política de reembolso?
"""

resposta = llm.invoke(prompt)
```

Custo Elevado

~US\$ 2 por chamada (input)
(GPT-4)

Contexto Limitado

GPT-4o (128k) não suporta sequer
um único livro técnico.

Lost in the Middle

Modelos perdem atenção em
contextos longos.

Conclusão:

*Colar tudo no prompt não escala e
degrada a performance.*

Ideia Central do RAG

Ideia-chave (Lewis et al., 2020):

Parametric knowledge (pesos do modelo) + **Non-parametric knowledge** (documentos externos) = **Resposta fundamentada**.



1. Pergunta

O usuário faz uma solicitação ao sistema.



2. Busca

Recuperação de trechos relevantes na base externa.



3. Geração

LLM raciocina e gera a resposta contextualizada.

*"O modelo não precisa saber a resposta — ele precisa saber **raciocinar** sobre ela. O conhecimento fica na base de dados."*

Definição Formal

O que é RAG?

É um framework que **condiciona a geração** do LLM a documentos recuperados dinamicamente, garantindo que a resposta considere os dados mais relevantes e ponderados para cada pergunta.



1. Retriever


Encontra os trechos certos na base de conhecimento externa de forma dinâmica.



2. Generator (LLM)

Gera a resposta final fundamentada exclusivamente nos trechos recuperados.

Pipeline do RAG



Exemplo Pipeline RAG



1. Query (Pergunta)

"Qual o prazo de entrega para o Nordeste?"



2. Recuperação

Pág. 12 do manual logístico:

"Entregas para regiões N/NE: 7 a 10 dias úteis."



3. Resposta Gerada

"Para o Nordeste, o prazo de entrega é de 7 a 10 dias úteis, conforme o manual logístico."

Comparação Direta



Vantagens

Redução de Alucinações



O modelo deixa de "adivinhar", ele lê antes de responder.

RAG reduz em até **38%** as alucinações factuais em tarefas de QA (Shi et al., 2023).

Mecanismo: System Prompt (Python)

```
prompt = """
Você é um assistente preciso.
Responda APENAS com base no contexto abaixo.
Se a resposta não estiver no contexto, diga "Não encontrado".

Contexto: {context}
Pergunta: {question}
"""
```

Ancoragem em Evidência

Isso não elimina alucinações, mas as **ancora em evidência verificável**.

Referência

Shi et al. (2023). *Large Language Models Easily Distracted*.
arXiv:2302.00093

Dados Atualizados



LLMs têm **knowledge cutoff**: qualquer evento após o treino é invisível.
Com **RAG**, basta atualizar a base de conhecimento, sem retreinar o modelo.

Exemplos de fontes dinâmicas integráveis:



APIs REST

Preços, estoque e dados transacionais em tempo real.



Bancos SQL

Consultas diretas a bancos estruturados.



Web Scraping

Monitoramento de normas regulatórias e notícias.



Auto-Indexação

Novos documentos processados e indexados automaticamente.

Acesso a Dados Privados



Privacidade e Isolamento de Dados

O modelo de treino jamais viu seus dados internos — e não deve ver (risco de vazamento). RAG permite o uso sem exposição ao provedor de IA.



Segurança da Base Vetorial

Controles de acesso rigorosos garantem que nem todo usuário recupere todos os documentos. Isso é resolvido com **metadata filtering** no retriever.

"O modelo passa a conhecer sua empresa, sem sair da sua infraestrutura."

Redução de Custo



Fine-tuning vs. RAG

Fine-tuning 7B: ~US\$ 500–2.000 por rodada. RAG é proporcional às queries, não ao volume de dados.



Modelos Menores e Locais

Use Llama 3 8B com qualidade de modelos gigantes. O contexto carrega o conhecimento necessário.

"Você paga pela inteligência do modelo, não pela memória dele."

Controle e Rastreabilidade



Fundamentação de Respostas

Cada resposta gerada é vinculada ao trecho exato do documento que a fundamentou.

Exemplo de Resposta Rastreável:

"O prazo de garantia é de 12 meses."



Fonte: contrato_modelo_v3.pdf

pág. 7, cláusula 4.2: "...garante o produto por 12 meses..."

Benefícios Diretos:

- **Auditoria & Compliance:** Essencial em setores regulados.
- **Contestação:** Usuário verifica a veracidade na fonte.
- **Debugging:** Identifica dados fonte desatualizados.

"Implementação: armazenar metadados (arquivo, página) junto ao embedding para retorno imediato na busca."

Quando Utilizar

Cenários Ideais

Use RAG quando pelo menos um destes critérios for verdadeiro:

Dados Privados

Dados não estão nos pesos do modelo. Ex: Manual interno, política da empresa.

Conhecimento Dinâmico

Muda com frequência. Ex: Preços, legislação, catálogo de produtos.

Alta Precisão

Erros têm custo alto. Setores: Jurídico, médico, financeiro.

Grande Volume

Milhares de PDFs ou base de conhecimento corporativa extensa.

Rastreabilidade

Obrigatória para auditoria, compliance e regulação.

Perfis de Acesso

Acesso diferenciado a documentos por papel (múltiplos usuários).

Exemplos Típicos



Bases de Conhecimento

FAQ interno indexado → funcionário pergunta → sistema recupera e responde com base na política vigente.



Documentos Extensos

Relatório de 300 páginas → chunked e indexado → analista faz perguntas específicas sem ler o documento inteiro.



FAQs Corporativos

perguntas frequentes de RH (férias, benefícios, jornada) → RAG responde com base no handbook atualizado, não no modelo genérico.



Manuais Técnicos


Técnico de campo pergunta como substituir uma peça → RAG busca no manual do equipamento específico (modelo, versão) e retorna o passo a passo correto.

Conhecimento Dinâmico

O Desafio dos Dados Voláteis

Preços, estoque, legislação e notícias mudam em tempo real. A solução é um pipeline de ingestão contínua que atualiza a base vetorial sem necessidade de retreinar o LLM.

Fluxo de Atualização Contínua




Quando Não Utilizar

RAG Pode ser Overkill

Situação	Por quê RAG não ajuda
Conhecimento geral (ex: API REST)	O modelo já sabe. Busca adiciona latência sem ganho
Prototipagem rápida / MVP	Complexidade desnecessária no início
Latência < 500ms é obrigatória	Etapa de retrieval adiciona 100–400ms típicos
Sem base de documentos estruturada	RAG sem qualidade = lixo na entrada, lixo na saída
Raciocínio puro / matemática / código	O problema não é de recuperação de informação

Custo vs Complexidade



Custo vs Complexidade

O que você passa a precisar gerenciar:



Vector Store

Gerenciamento de bancos vetoriais como Chroma, Pinecone, Weaviate ou pgvector.



Embedding Models

Escolha e manutenção de modelos (OpenAI, sentence-transformers, etc).



Pipeline de Dados

Ingestão, processamento e atualização constante de documentos.



Avaliação de Retrieval

Métricas específicas para a qualidade da busca, independentes do LLM.

"Nem todo problema precisa de RAG — mas todo sistema de QA em domínio privado provavelmente precisa."

Aplicações Reais

Chatbots Corporativos



Suporte Interno

Funcionário pergunta sobre política de home office → **RAG** busca no sistema de RH atualizado.



Onboarding

Novo colaborador faz perguntas sobre processos → **RAG** indexa toda documentação interna.



Help Desk de TI

Usuário reporta erro → **RAG** busca em base de tickets anteriores.

Suporte Técnico

Problema clássico: Suporte de nível 1 não encontra a solução no manual de 800 páginas.

Com RAG: Técnico descreve o erro → sistema recupera o trecho exato do manual/log.

Tabela de fontes de dados típicas

Fonte	Formato	Conteúdo
Manuais técnicos	PDF	Procedimentos, especificações
Logs de sistemas	TXT/JSON	Erros recorrentes e soluções
Tickets resolvidos	CSV/DB	Casos anteriores
Documentação de API	Markdown	Endpoints, parâmetros, exemplos

Jurídico

Contexto: Contratos, leis, pareceres e acórdãos são documentos extensos com linguagem técnica e alta criticidade.

Desafios e Soluções com RAG

Desafio

Volume: Processos com milhares de páginas

Precisão: Erros podem custar ações judiciais

Atualização: Mudanças constantes em leis

Rastreabilidade: Exigência de fundamentação

Como RAG endereça

Recupera apenas as cláusulas relevantes

Resposta ancorada em texto exato do documento

Re-indexação atualiza a base sem retreino

Resposta cita artigo, página e cláusula

Comércio Eletrônico

Problema: catálogo com 50.000 SKUs — nenhum LLM foi treinado neles.

Com RAG: base de produtos indexada → cliente pergunta, sistema recupera o produto certo e responde com dados reais.

Casos de Uso Concretos

Pergunta do Cliente	Ação do RAG
"Este notebook roda o Premiere Pro?"	Busca ficha técnica e responde com especificações reais de GPU/RAM.
"Qual produto substitui o X que saiu de linha?"	Compara ficha dos produtos e sugere equivalente.
"Tem desconto para compra acima de 10 unidades?"	Busca na tabela de preços B2B atualizada.

Take home Message

Solução de Problemas Reais

RAG resolve o isolamento dos LLMs: conhecimento congelado, alucinações e falta de acesso a dados privados.

O Pipeline RAG

Recuperar → Inserir no Prompt → Gerar

Simple na concepção, mas extremamente poderoso na prática corporativa.

Vantagens Mensuráveis

- Redução drástica de alucinações
- Dados atualizados sem retreino
- Rastreabilidade completa da fonte
- Custo operacional menor que fine-tuning

Limitações Importantes

RAG não é "bala de prata". Evite se:

- O conhecimento necessário é puramente geral
- A latência é um requisito ultra-crítico
- Não existe uma base de conhecimento de qualidade