




UNICAMP




Casos de Uso de RAG

Prof. Dr. André Gomes Regino

regino@unicamp.br

Agenda



01

Por que RAG é adotado

02

Chatbots Corporativos

03

Suporte Técnico

04

Jurídico

05

Saúde

06

E-commerce

07

Educação

08

Take-home messages


Objetivos

1. **Identificar** em qual domínio RAG agrega mais valor e por quê
2. **Descrever** a arquitetura RAG específica de cada caso de uso
3. **Reconhecer** os desafios técnicos e éticos particulares de cada setor
4. **Avaliar** se RAG é a abordagem certa para um problema

Por que o RAG é Adotado?

- Empresas precisam:
 - respostas confiáveis
 - uso de dados internos
 - atualização constante

Padrão Comum nos Casos



Chatbots Corporativos

Problema

Consequências mensuráveis:

Tempo para encontrar política interna

20–45 min

por ocorrência

Chamados de RH (benefícios/férias)

30–40%

do volume total de help desk

Custo de onboarding por funcionário

US\$ 1k–3k

em tempo de suporte humano

Informação desatualizada

Erros de compliance e retrabalho

O Problema: Barreiras à Produtividade



Informação Fragmentada

Funcionários não encontram informações em SharePoint, Confluence, e-mails e PDFs sem organização.



Sobrecarga de Suporte

RH e TI recebem 40–60% de perguntas repetitivas que poderiam ser automatizadas (McKinsey, 2023).



Dificuldade de Acesso

O problema não é a falta de documentos, mas a falta de acesso eficiente ao que já existe.



Busca Ineficiente

Barras de busca tradicionais falham por não entenderem a intenção por trás das palavras-chave.

Solução com RAG



Políticas de RH (PDF)

Férias, remuneração e código de conduta.



Processos Operacionais

Confluence/Notion: fluxos de aprovação e onboarding.



Guias de Sistemas (Markdown)

Como usar as ferramentas internas da empresa.



FAQs Históricas (CSV)

Perguntas e respostas já resolvidas pelo RH.

Base de conhecimento indexada para Chatbot Corporativo

Solução com RAG: Implementação

```
# Instalação das dependências
# pip install langchain==0.3.x langchain-openai==0.2.14 langchain-community==0.3.20 chromadb==0.6.x

from langchain_community.vectorstores import Chroma
from langchain_openai import OpenAIEmbeddings, ChatOpenAI
from langchain_core.prompts import ChatPromptTemplate
from langchain_core.output_parsers import StrOutputParser
from langchain_core.runnables import RunnablePassthrough

vectorstore = Chroma(persist_directory="./db_corporativo",
embedding_function=OpenAIEmbeddings(model="text-embedding-3-small"))

# Filtro por departamento via metadata
retriever = vectorstore.as_retriever(search_kwargs={"k": 5, "filter": {"departamento": "rh"}})

prompt = ChatPromptTemplate.from_template("""Você é o assistente interno...""")

chain = ( {"context": retriever | (lambda docs: "\n\n".join(d.page_content for d in docs)), "question":
RunnablePassthrough()} | prompt | ChatOpenAI(model="gpt-4o-mini", temperature=0) | StrOutputParser() )

print(chain.invoke("Quantos dias de férias tenho direito após 2 anos?"))
```

Resultado e Monitoramento

📈 Anthropic (2024): Redução de 30% no tempo de onboarding com chatbots RAG internos

O que monitorar em produção:



Taxa de "não encontrado"

Indica gaps na base de documentos que precisam ser preenchidos.



Feedback Negativo

Sinaliza respostas incorretas, alucinações ou falta de contexto do modelo.



Uso de Documentos

Revela quais informações os funcionários mais buscam e necessitam no dia a dia.

Suporte Técnico

Problemas no Suporte Técnico



Documentação Fragmentada

Manuais de centenas de páginas, APIs em múltiplos repositórios e logs não estruturados dificultam o acesso à informação.



Baixa Eficiência Operacional

Tempo médio para Resolução (MTTR) elevado devido à necessidade de consultar múltiplas fontes.
70% dos casos N1 já possuem solução documentada.

Análise de Custos (Gartner 2023)

Comparativo de custo por chamado N1:

Humano: US\$ 15,00

Automatizado com RAG: < US\$ 0,50

Solução com RAG

O diferencial aqui: múltiplas fontes heterogêneas indexadas juntas

Fonte	Formato	Conteúdo	Estratégia de chunking
Manuais técnicos	PDF	Procedimentos, specs	Por seção (header-based)
FAQs resolvidas	CSV / JSON	Pergunta + solução	Cada par = 1 chunk
Tickets históricos	Banco SQL	Descrição + resolução	Por ticket completo
Documentação de API	Markdown	Endpoints, parâmetros	Por endpoint

Solução Técnica com RAG

1. Ingestão de Dados

Carregamento de fontes heterogêneas preservando metadados.

```
loader_manual = PyPDFLoader("manual.pdf")
loader_tickets = CSVLoader("tickets.csv",
                           metadata_columns=["produto", "versao"])
todos_docs = loader_manual.load() + loader_tickets.load()
```

2. Chunking Estruturado

Divisão em pedaços com overlap para contexto.

```
splitter = RecursiveCharacterTextSplitter(
    chunk_size=500,
    chunk_overlap=50
)
chunks = splitter.split_documents(todos_docs)
```

3. Indexação em Vectorstore

Criação de embeddings e persistência no banco Chroma.

```
vectorstore = Chroma.from_documents(
    chunks,
    OpenAIEmbeddings(model="text-embedding-3"),
    persist_directory="./db_suporte"
)
```

4. Recuperação com Filtros

Busca semântica filtrada por atributos de metadados.

```
retriever = vectorstore.as_retriever(
    search_kwargs={
        "k": 6, "filter": {"produto": "X"}
    }
)
```

Solução Técnica com RAG

1. Chunks por seção em Markdown

Ideal para manuais técnicos estruturados com headers.

```
from langchain_text_splitters import MarkdownHeaderTextSplitter
headers_to_split_on = [
    ("#", "capitulo"), ("##", "secao"), ("###", "subsecao")
]
splitter = MarkdownHeaderTextSplitter(
    headers_to_split_on=headers_to_split_on,
    strip_headers=False # mantém o título
)
```

2. Chunks por seção em PDF

Estratégia baseada em separadores textuais para PDFs.

```
from langchain_text_splitters import RecursiveCharacterTextSplitter

splitter = RecursiveCharacterTextSplitter(
    separators=["\nCAPÍTULO ", "\n\n", "\n"],
    chunk_size=2000,
    chunk_overlap=0,
    keep_separator=True
)
```


Exemplo de Resultado (RAG)

Pergunta do Técnico

"Equipamento-X exibe erro E-403 após atualização de firmware 3.2"

RAG: Documentos Recuperados

[1] Manual v3.2, p.47

"Erro E-403 indica falha na calibração do sensor..."

[2] Ticket #8821 (resolvido)

"Após update 3.2, E-403 corrigido com reset..."

Resposta Gerada pela IA

"O erro E-403 no firmware 3.2 indica falha de calibração do sensor de temperatura. **Solução:** execute o reset de fábrica (Menu > Config > Reset) e recalibre conforme seção 4.7 do manual."

Confiança do Sistema

Isso resolveu 94% dos casos similares (Ticket #8821, #9034, #9187).

Jurídico

Problema

Tipo de Documento	Volume Típico	Desafio
Contratos Comerciais	Centenas por empresa/ano	Cláusulas similares com diferenças críticas
Jurisprudência (STF, STJ, TRTs)	Milhões de acórdãos	Encontrar precedente específico
Legislação (Federal/Estadual)	Dezenas de milhares de leis	Atualizações frequentes e referências cruzadas
Pareceres Internos	Centenas por escritório	Reutilizar trabalho já feito
Petições Históricas	Milhares	Reaproveitar argumentação vencedora

Solução com RAG



Citação Obrigatória

Citação de fonte em toda resposta: número do documento, artigo e página.



Chunking Estruturado

Processamento que respeite a estrutura legal (artigos, parágrafos, incisos).



Metadados Ricos

Inclusão de tipo de documento, data, tribunal e número de processo.

“Sem evidência, não serve”

Resultado da Consulta RAG



Consulta do Usuário

"Quais são as obrigações do controlador de dados em caso de incidente de segurança segundo a LGPD?"

Resposta Gerada

Conforme a **LGPD [Lei 13.709/2018, Art. 48]**, o controlador deve comunicar à autoridade nacional e ao titular dos dados a ocorrência de incidente de segurança que possa acarretar risco ou dano relevante, em prazo razoável [§ 1º].

A comunicação deve conter:

- Natureza dos dados e informações sobre os titulares envolvidos;
- Medidas técnicas e de segurança utilizadas;
- Riscos relacionados e medidas adotadas para reversão/mitigação [§ 2º].

Saude

Limitações do LLM Isolado

O Desafio na Saúde: Atualização e Precisão

O conhecimento clínico é crítico e publicado diariamente. Uma falha pode causar dano direto ao paciente. O custo é humano.



Dosagem Incorreta

Cálculos baseados em peso ou condições específicas podem ser ignorados pelo modelo, que sugere doses padrão perigosas.



Guidelines Obsoletos

Protocolos atualizados após o treino resultam em respostas baseadas em diretrizes desatualizadas da OMS/CFM.



Interações Raras

Combinações específicas de medicamentos podem não constar no treino, levando o modelo a falhar na detecção de riscos.

Solução com RAG

<> IMPLEMENTAÇÃO (LANGCHAIN)

```
# Dependências
pip install langchain==0.3.x langchain-openai==0.2.14

# Imports & Configuração
from langchain_openai import ChatOpenAI
from langchain_community.vectorstores import Chroma
from langchain_core.prompts import ChatPromptTemplate

# Retriever
retriever = Chroma(
    persist_directory="./db_clinico",
    embedding_function=OpenAIEmbeddings()
).as_retriever(search_kwargs={"k": 5})

# Chain
chain = (
    {"context": retriever | format_docs,
    "question": RunnablePassthrough()}
    | prompt_clinico
    | ChatOpenAI(model="gpt-4o", temperature=0)
    | StrOutputParser()
)
```

🧠 PROMPT SYSTEM: REGRAS CLÍNICAS

"Você é um assistente de apoio à decisão clínica..."

- ✅ **Fidelidade:** Responda APENAS com base nos documentos fornecidos.
- 🔗 **Rastreabilidade:** Cite a fonte (artigo, guideline, bula) para cada informação.
- 👁️ **Transparência:** Se não houver informação, diga explicitamente.
- 🛡️ **Segurança:** Especifique sempre a fonte e data para dosagens.

⚠️ AVISO OBRIGATÓRIO

Esta informação é de apoio à decisão. A decisão clínica final é responsabilidade exclusiva do profissional de saúde habilitado.

Variáveis: {context}, {question}

Resultado da Consulta



Pergunta do Médico

"Qual o protocolo atual para trombólise em AVC isquêmico agudo em paciente com 78 anos e histórico de sangramento GI há 6 meses?"



RAG Recupera:

- [1] Diretriz AHA/ASA 2023 — Critérios de exclusão para tPA
- [2] ANVISA bula Alteplase 2023 — Contraindicações relativas



Resposta Gerada:

"Segundo a Diretriz AHA/ASA (2023), sangramento GI nos últimos 3 meses é contraindicação relativa ao tPA. Com 6 meses, a contraindicação absoluta foi superada, mas a decisão requer avaliação risco-benefício individualizada [AHA/ASA 2023, Tabela 7, p. 14]."



AVISO OBRIGATÓRIO

A decisão clínica final é responsabilidade do profissional habilitado.

E-commerce

Problema

67%

Desistem por falta de informação

Forrester Research, 2023

US\$ 5–15

Custo médio de atendimento humano

Por conversa no chat

20–30%

Devolução por frustração

"Produto não era o esperado"

< 40%

Eficácia da busca por palavra-chave

Coveo, 2023

Problema

Cenário do Cliente

"notebook para edição de vídeo 4K"



Busca por Keyword

Retorna apenas notebooks que contenham exatamente **"4K"** no título.

LIMITAÇÃO:

Ignora produtos descritos como "UHD", "4096x2160" ou termos técnicos equivalentes.



RAG sobre Catálogo

Interpreta a **INTENÇÃO** do usuário e requisitos técnicos reais.

- Busca por GPU dedicada e RAM $\geq$ 16GB
- Verifica suporte a codecs (ex: H.265)
- Retorna resultados **semanticamente relevantes**

Solução com RAG

Tabela de Base de Conhecimento do E-commerce

Fonte	Conteúdo	Formato
Catálogo de produtos	Fichas técnicas, specs, dimensões	JSON/CSV estruturado
Descrições enriquecidas	Benefícios, casos de uso, diferenciais	Texto livre
Reviews de clientes	Opiniões reais, prós/contras, uso	Texto não estruturado
Tabela de compatibilidade	Produto X compatível com Y	CSV relacional
FAQ de produtos	Perguntas históricas + respostas	Par P&R
Estoque e preços	Disponibilidade atual	API em tempo real

Solução com RAG: Implementação

```
pip install langchain==0.3.x langchain-openai==0.2.14 langchain-community==0.3.20 chromadb==0.6.x
from langchain_community.vectorstores import Chroma
from langchain_openai import OpenAIEmbeddings, ChatOpenAI
from langchain_core.documents import Document

# Criando documentos com metadados ricos de produto
produtos = [
    Document(
        page_content="Notebook ProMax X15 - GPU RTX 4070, 32GB RAM, i7-13700H...",
        metadata={
            "sku": "NB-X15-001",
            "preco": 8999.00,
            "em_estoque": True
        }
    ),
    # ... outros produtos
]

vectorstore = Chroma.from_documents(
    produtos,
    OpenAIEmbeddings(model="text-embedding-3-small")
)
```

Solução com RAG: Lógica da Chain

```
# Configuração do Retriever com Filtro de Estoque
retriever = vectorstore.as_retriever(
    search_kwargs={
        "k": 4,
        "filter": {"em_estoque": True} # Disponibilidade
    }
)

# Template de Prompt Especializado
prompt = ChatPromptTemplate.from_template(""" ... """)

# Definição da LCEL Chain
chain = (
    {"context": retriever | (lambda docs: "\n\n".join(d.page_content for d in docs)),
     "question": RunnablePassthrough()}
    | prompt
    | ChatOpenAI(model="gpt-4o-mini", temperature=0.2)
    | StrOutputParser()
)

print(chain.invoke("Preciso de um notebook que rode Premiere Pro sem travar"))
```

Exemplo de Interação: Vendas Técnicas



CLIENTE

"Tenho um setup para live streaming com 3 câmeras. Qual notebook aguenta isso sem aquecer?"



RAG RECUPERA (CONTEXTO)

Fichas técnicas de GPUs, reviews de performance em streaming e FAQs de dissipação térmica.

RESPOSTA DO SISTEMA



"Para live streaming com 3 câmeras, recomendo o **ProMax X15** (R\$ 8.999). Equipado com RTX 4070 e gerenciamento térmico avançado — 94% das reviews confirmam estabilidade térmica.

Alternativa econômica: **Dell G15** (R\$ 5.999), adequado para até 2 câmeras simultâneas."

Educação

Problema



Materiais Dispersos

Slides, PDFs, vídeos e artigos sem conexão, dificultando a organização do estudo.



Escalabilidade Limitada

Impossibilidade de atendimento individualizado em turmas com centenas de alunos.

Risco: LLM Isolado na Educação

- Alucinação: pode ensinar conteúdo divergente do escolhido pelo professor.
- Falta de contexto: ignora o que já foi coberto no curso.
- Desajuste de nível: simplifica demais ou complexifica além da turma.



A Solução: RAG

"O tutor responde apenas com base no material do curso, garantindo fidelidade ao conteúdo e profundidade correta."

Solução com RAG: Implementação


```
# Dependências e Imports
# pip install langchain==0.3.x langchain-openai==0.2.14 ...
from langchain_community.document_loaders import PyPDFDirectoryLoader
from langchain_text_splitters import RecursiveCharacterTextSplitter
from langchain_community.vectorstores import Chroma
from langchain_openai import OpenAIEmbeddings
...

# 1. Carregamento dos Documentos
loader = PyPDFDirectoryLoader("./material_curso/")
docs = loader.load()

# 2. Divisão em Chunks
splitter = RecursiveCharacterTextSplitter(chunk_size=500, chunk_overlap=50)
chunks = splitter.split_documents(docs)

# 3. Criação do Vector Store
vectorstore = Chroma.from_documents(
    chunks,
    OpenAIEmbeddings(model="text-embedding-3-small"),
    persist_directory="./db_curso"
)
```

Solução com RAG: Resultado



```
# Configuração do Retriever e Prompt do Tutor
retriever = vectorstore.as_retriever(search_kwargs={"k": 5})

prompt_tutor = ChatPromptTemplate.from_template("""
    Você é um tutor assistente do curso "Sistemas Inteligentes com LLMs" (UNICAMP).
    Seu papel é ajudar o aluno a compreender o conteúdo – não dar a resposta direta.
    REGRAS:
    1. Responda APENAS com base no material do curso abaixo
    2. Se a dúvida não estiver no material, diga: "Este tópico não está no material..."
    3. Estimule o raciocínio: termine com uma pergunta de reflexão quando possível
    4. Cite de qual aula/slide veio a informação
    Material do curso: {context} | Dúvida do aluno: {question}
""")

# Definição da Chain RAG
chain = (
    {"context": retriever | (lambda docs: "\n\n".join(
        f"[{d.metadata.get('source', '?')}] \n {d.page_content}" for d in docs)),
    "question": RunnablePassthrough()}
    | prompt_tutor
    | ChatOpenAI(model="gpt-4o-mini", temperature=0.3)
    | StrOutputParser()
)

# Execução
print(chain.invoke("Qual a diferença entre chunking fixo e por estrutura?"))
```


Take Home Message

O padrão RAG é o mesmo — o que muda é o contexto:

Domínio	Diferencial Crítico	Alerta Específico
Chatbot Corporativo	Filtro de acesso por departamento/perfil	Dados privados: on-premise ou cloud controlada
Suporte Técnico	Múltiplas fontes heterogêneas + metadados de produto/versão	Manter base de tickets históricos atualizada
Jurídico	RAG híbrido + citação obrigatória de fonte	Nunca sem citação — alucinação aqui tem custo legal
Saúde	Temperatura=0, disclaimer obrigatório, fontes datadas	RAG apoia — nunca substitui profissional
E-commerce	Metadados de estoque em tempo real + filtro disponibilidade	Catálogo desatualizado = resposta incorreta
Educação	Prompt pedagógico: estímulo ao raciocínio, não entrega de resposta	Restringir ao material do curso para consistência



UNICAMP



Casos de Uso de RAG

Prof. Dr. André Gomes Regino
regino@unicamp.br