





UNICAMP



Avaliação I

Prof. Dr. André Gomes Regino
regino@unicamp.br

Agenda



1. Motivação: Por que avaliar LLMs?
2. Avaliação Humana e Escala Likert
3. LLM-as-a-Judge
4. Métricas Textuais (BLEU, ROUGE, BERTScore)
5. Avaliação de Custo, Latência e Throughput
6. Modelos via API vs Locais (RAM, GPU, Quantização)
7. Benchmarks e suas Limitações

Objetivos

1. **Escolher** a abordagem de avaliação para um contexto específico
2. **Implementar** e interpretar LLM-as-a-Judge com escalas Likert
3. **Calcular** e interpretar métricas textuais clássicas
4. **Estimar** custo de um pipeline com LLMs
5. **Decidir** entre modelo via API ou local

Cenário real: Você tem dois modelos para um chatbot de atendimento. Ambos "respondem". Qual colocar em produção?

Dimensão	Modelo A	Modelo B
Acurácia (MMLU)	85%	80%
Custo / 1M tokens	\$15.00	\$0.15
Latência (p95)	4.2s	0.8s
Taxa de alucinação	3%	9%
ROUGE-L (respostas)	0.71	0.68

Pergunta central: "Qual modelo é melhor para o meu contexto?"
A resposta depende do que você mede e de como você mede.

O que Significa “um bom LLM”?

A resposta depende da aplicação



Chatbot

Foco: Naturalidade



Jurídico

Foco: Precisão



Saúde

Foco: Confiabilidade



Código

Foco: Compilação correta



RAG


Foco: Fidelidade ao contexto



Atendimento

Foco: Custo + Latência

Tipos de Avaliação



Qualitativa (Humana)

Foco em julgamento humano detalhado.

- Avaliadores julgam clareza, utilidade e naturalidade.
- Alta validade de resultados.
- Baixa escalabilidade e alto custo.
- Ferramenta: Escala Likert (1–5).

Quantitativa Automática

Métricas textuais baseadas em referência.

- Compara saída gerada com texto de referência.
- Exemplos: BLEU, ROUGE, BERTScore.
- Rápida e 100% reproduzível.
- Depende de dados de referência de alta qualidade.

Automática com LLM

O paradigma "LLM-as-a-Judge".

- Um LLM avalia a qualidade da saída de outro LLM.
- Combina pontuações com feedback textual.
- Zheng et al. (2023) – MT-Bench.
- Escalável e mais rápido que humanos.

Pipeline de Avaliação

Etapas do Processo



Ponto Crítico

O dataset de teste deve ser **representativo** do caso de uso real.

"Datasets genéricos geram conclusões genéricas."

Boas Práticas

- Mínimo de **50-100 exemplos** por categoria de teste
- Incluir **casos de borda** (edge cases) para maior robustez

O que é avaliado?

Critérios fundamentais para análise de qualidade de LLMs:


- **Coerência:** Lógica e fluidez do texto.
- **Factualidade:** Veracidade das informações.
- **Clareza:** Facilidade de compreensão.
- **Utilidade:** Atendimento ao propósito inicial.
- **Educação:** Tom apropriado e polido.
- **Criatividade:** Originalidade e inovação na resposta.

Principais Desafios

Obstáculos na implementação em escala:

- **Caro:** Necessita de especialistas remunerados.
- **Lento:** Limitado pelo ritmo de leitura e análise humana.
- **Subjetivo:** Riscos de viés e discordância entre juízes.
- **Escalabilidade:** Difícil de manter para grandes datasets.

Escala Likert



CrITÉRIOS de Avaliação (Escala 1 a 5)

Clareza

A resposta é fácil de entender?

Precisão

As informações estão corretas?

Relevância

Responde ao que foi perguntado?

Completude

Cobre todos os aspectos necessários?

Exemplo de Instrução:

"Leia a pergunta e a resposta abaixo. Avalie de 1 a 5 cada critério. Não considere o estilo de escrita, apenas o conteúdo."

Pergunta: [...]

Resposta: [...]

CrITÉrios: [...]


Resultado Final

Média ponderada dos critérios

(pesos podem variar por aplicação)



Problemas da Avaliação Humana



Subjetividade / Discordância

Divergência de critérios:

Dois avaliadores podem atribuir notas drasticamente diferentes para a mesma resposta.

Baixa Correlação (Cohen's Kappa):

$$\kappa \approx 0.3 - 0.5$$

Classificado como "fraco a moderado"

Fadiga e Viés Temporal


Limitação por Sessão:

Queda acentuada na qualidade da análise após ~100–200 avaliações contínuas.

Viés de Fadiga:

Avaliadores tendem a ser mais permissivos (notas mais altas) conforme o cansaço aumenta.

Problemas de Avaliação Humana



- **Escalabilidade e Custo**

O GPT-4 gera **milhões de respostas/dia** em produção. Avaliar apenas 0.1% manualmente já exige **dezenas de milhares** de avaliações humanas dispendiosas.


Custo Estimado (Amazon MTurk)

Volume (Respostas)	Custo Unitário	Custo Total
1.000	\$0.10	\$100
10.000	\$0.10	\$1.000
100.000	\$0.10	\$10.000

→ Solução: Automatizar com *LLM-as-a-Judge*

LLM-as-a-Judge

LLM como Avaliador



Conceito Principal

Um modelo analisa respostas produzidas por outro modelo.

O que o "Juiz" pode avaliar:



Qualidade



Factualidade



Completeness




**Alinhamento ao
Prompt**



Segurança

Exemplo de Prompt de Avaliação



System Instruction

"Você é um avaliador imparcial de respostas de IA."

Input Template (User)

[Pergunta]: {pergunta}

[Resposta do modelo]: {resposta}

Avalie nos critérios (1-5):


- Factualidade
- Clareza
- Completude

Formato de Saída (JSON)

O modelo deve retornar exclusivamente dados estruturados para automação.

```
{  
  "factualidade": X,  
  "clareza": X,  
  "completude": X,  
  "justificativa": "..."  
}
```

Vantagens



Escalabilidade

Avalia milhares de respostas em minutos.

- GPT-4o: ~1.000 avaliações em < 5 min (com paralelismo)

Consistência

- Critérios mais uniformes que humanos
- Sem fadiga ou variação de humor
- Cohen's Kappa (juiz vs. juiz): $\kappa \approx 0.7-0.85$


Automação

- Integra em pipelines de CI/CD
- Benchmarks contínuos a cada nova versão

Custo

- Humano: ~\$0.10 / resposta
- GPT-4o: ~\$0.003 / resposta
- Llama-3-70B: ~\$0.0003 / resposta

Limitações



Viés de Resposta

- **Verbosity:** Prefere respostas longas (500 vs 50 palavras).
- **Self-enhancement:** GPT-4 prefere saídas do próprio GPT-4.

Instabilidade

- Temperatura > 0 gera notas variáveis para a mesma entrada.
- **Solução:** Usar $temp=0$ + múltiplas execuções + média.

Prompt e Ordem

- **Position bias:** Prefere a 1ª opção em avaliações A/B.
- **Sensibilidade:** Pequenas mudanças alteram o resultado.



Regra de Ouro: Nunca use o mesmo modelo como juiz e avaliado

Isso gera um conflito de interesse sistemático nos resultados.

O LLM Julga Igual o Humano?

Objetivo: comparar notas humanas vs. notas do LLM-juiz



1. Humanos

Avaliam N respostas (ex: 200)



2. LLM-Juiz

Avalia as mesmas N respostas




3. Correlação

Calcula-se a relação entre as notas

⚠ Atenção: Correlação $\neq$ Qualidade

Maior correlação = mais parecido com o humano, mas não necessariamente mais correto.
Se o humano é um avaliador ruim, correlação alta não garante qualidade.

Exemplo de Correlação



Métodos de Medição: **Pearson**, **Spearman Rho** e **Kendall Tau**

Interpretação Prática

Valor
Significado

0,9 Muito forte

0,7 Boa

0,5 Moderada

0,2 Fraca

< 0 Inversamente

Quando usar cada uma:



Pearson

Ideal para **dados contínuos** que seguem uma **distribuição normal**.



Spearman Rho

Para **dados ordinais** (ex: notas 1–5). É significativamente mais robusto a **outliers**.




Kendall Tau (τ)

Recomendado para **datasets pequenos**. Oferece uma estimativa mais conservadora da relação.

Métricas Textuais

Avaliação Automática Clássica



Métricas automáticas clássicas

BLEU

MELHOR PARA
Tradução automática

LIMITAÇÃO
Ignora sinônimos

ROUGE

MELHOR PARA
Sumarização de textos

LIMITAÇÃO
Sem compreensão
semântica

METEOR

MELHOR PARA
Tradução + paráfrase

LIMITAÇÃO
Mais lento

BERTScore

MELHOR PARA
Textos livres, QA

LIMITAÇÃO
Depende do modelo BERT

Sim. Semânt.

MELHOR PARA
Recuperação, RAG

LIMITAÇÃO
Sensível ao embedder

Todas comparam: **resposta gerada** ↔ **resposta de referência**

BLEU (Bilingual Evaluation Understudy)

Muito usada em tradução automática. Compara sequências de palavras (n-gramas) entre texto gerado e referência.

Intuição e Exemplos

REFERÊNCIA: "O gato sentou no tapete"

Hipótese A: "O gato sentou no tapete" **BLEU $\approx$ 1.0** ✓

Hipótese B: "O felino ficou sobre o tapete" **BLEU $\approx$ 0.3** (sinônimos penalizados)

Hipótese C: "tapete tapete tapete tapete" **BLEU $\approx$ 0.0** (brevity penalty)

BLEU – Código

```
from nltk.translate.bleu_score import sentence_bleu
ref = [["o", "gato", "sentou", "no", "tapete"]]
hyp = ["o", "gato", "sentou", "no", "tapete"]

print(sentence_bleu(ref, hyp)) # 1.0
```

Nota: A função `sentence_bleu` espera uma lista de referências (múltiplas possibilidades) e uma única hipótese.

ROUGE (Recall-Oriented Understudy for Gisting Evaluation)

Foco em sumarização: mede quanto da referência está presente no texto gerado.

ROUGE-1

Sobreposição de unigramas (palavras únicas)

ROUGE-2

Sobreposição de bigramas (pares de palavras)

ROUGE-L

Subsequência comum mais longa (LCS)

Exemplo de Cálculo

Ref: "O modelo respondeu corretamente a pergunta"

Ger: "O modelo acertou a resposta da pergunta"

ROUGE-1 Recall = tokens comuns / tokens na referência

= {o, modelo, a, pergunta} / 6 $\approx$ 0.67


ROUGE Código

```
from rouge_score import rouge_scorer  
scorer = rouge_scorer.RougeScorer(['rouge1', 'rougeL'])  
scores = scorer.score(  
    "O modelo respondeu corretamente a pergunta",  
    "O modelo acertou a resposta da pergunta"  
)
```

Saída do Cálculo (Scores):

```
# rouge1: P=0.62, R=0.67, F=0.64  
# rougeL: P=0.50, R=0.50, F=0.50
```

Similaridade Semântica



Conceito & Exemplo

Comparação de frases com mesmo significado:

"Carro muito rápido" vs "Veículo extremamente veloz"

BLEU $\approx$ **0.0** (sem palavras comuns)

Cosseno $\approx$ **0.94** (embeddings)

BERTScore (ICLR 2020)

- Compara tokens individuais via BERT
- Alta granularidade (token-level)
- Melhor correlação humana que BLEU/ROUGE

Modelos Recomendados

Multilíngue: `paraphrase-multilingual-MiniLM-L12-v2`

PT-BR: `neuralmind/bert-base-portuguese-cased`

Cálculo de Similaridade


```
from sentence_transformers import SentenceTransformer, util  
  
model = SentenceTransformer('all-MiniLM-L6-v2')  
e1 = model.encode("Carro muito rápido")  
e2 = model.encode("Veículo extremamente veloz")  
  
sim = util.cos_sim(e1, e2)  
  
print(f"Similaridade: {sim.item():.3f}")
```

Similaridade: 0.944

Custo

Avaliação de Custo


APIs cobram por: **input tokens + output tokens**

Modelo	Input (\$/M tok.)	Output (\$/M tok.)
GPT-4o	 \$2.50	 \$10.00
GPT-4o mini	 \$0.15	 \$0.60
Claude 3.5 Sonnet	 \$3.00	 \$15.00
Claude 3 Haiku	 \$0.25	 \$1.25
Gemini 1.5 Flash	 \$0.075	 \$0.30
Llama 3.1-70B*	\$0.00	\$0.00

*rodando localmente (custo de infraestrutura separado)

(referência maio/2025)

Avaliação de Custo



Cenário: Chatbot de Atendimento

Parâmetros do Cenário

Média: 500 input + 300 output tokens / conversa **Volume:** 100.000 conversas/mês

GPT-4o

$(500 \times \$2.50 + 300 \times \$10.00) / 1M \times 100k$

\$425 /mês

GPT-4o mini

$(500 \times \$0.15 + 300 \times \$0.60) / 1M \times 100k$

\$25.50 /mês

Latência (p95)

Tempo que 95% das requisições levam para ser processadas.

Throughput

Volume de requisições processadas por segundo (vazão).

Modelos via API vs Modelos Locais




Vantagens: privacidade, controle total, sem custo por token

Desvantagens: exige hardware, manutenção, modelos menores

Ferramentas para rodar modelos localmente:

Ferramenta	Característica
Ollama	CLI simples, fácil de usar, CPU+GPU
llama.cpp	CPU-first, GGUF, muito eficiente
vLLM	Alta performance em GPU, produção
LM Studio	Interface gráfica, ideal para testes
HuggingFace	Ecossistema completo, transformers

Limitações de Hardware



Regra Geral: ~2 bytes por parâmetro (FP16)

Exemplo: Modelo 7B ≈ 14 GB de VRAM




Modelo	VRAM (FP16)	Hardware Recomendado
Llama 3.1 3B	~6 GB	RTX 3060 (12 GB)
Llama 3.1 8B / Mistral 7B	~14–16 GB	RTX 3090 (24 GB)
Llama 3.1 70B	~140 GB	2× A100 (80 GB)
Llama 3.1 405B	~810 GB	8× A100 (80 GB)



Quantização 4-bit: Llama 3.1 8B (Q4) ≈ 4.5 GB | Llama 3.1 70B (Q4) ≈ 40 GB (**2× RTX 3090**)

Sem GPU? CPU com llama.cpp (~5–10 tok/s) • **Dica:** Se não cabe na VRAM, use RAM + offloading (processamento lento).

Quantização




Representar os pesos do modelo com menos bits para reduzir memória sem necessidade de retreinamento.

Formato	Bits/peso	Memória	Qualidade	Uso Típico
FP32	32 bits	4× FP16	Referência	Treinamento
FP16	16 bits	baseline	≈ FP32	Inferência GPU
INT8	8 bits	0.5× FP16	-1 a -2%	Prod. CPU/GPU
Q4_K_M	4 bits	0.25× FP16	-2 a -5%	Local CPU/GPU
Q2_K	2 bits	0.125× FP16	-10 a -20%	Hardware muito limitado

 **Dica:** A quantização 4-bit (Q4) é o "ponto ideal" (sweet spot) para rodar modelos grandes em hardware local com perda mínima de qualidade percebida.

Quantização – Código




Implementação com bitsandbytes (HuggingFace)

```
from transformers import AutoModelForCausalLM, BitsAndBytesConfig  
quant = BitsAndBytesConfig(load_in_4bit=True)  
model = AutoModelForCausalLM.from_pretrained(  
    "meta-llama/Llama-3.1-8B", quantization_config=quant  
)
```

 **Impacto na VRAM:** ~16 GB → ~4.5 GB (com Q4)


Escolhendo um Modelo

Árvore de Decisão Simplificada



💡 **Recomendação:** sempre avaliar o modelo no seu próprio dataset antes de escolher – benchmarks genéricos podem enganar.

Benchmarks



MMLU

Conhecimento em 57 áreas (medicina, direito, ciências...) — múltipla escolha

HELM

Suite ampla: acurácia, calibração, fairness, robustez, eficiência

BIG-Bench

204 tarefas diversas além de NLP tradicional

HumanEval

Geração de código Python — pass@k


Arena Elo

Ranking via preferência humana (Chatbot Arena)



Dica: a escolha do benchmark depende do caso de uso específico da aplicação.

Problema dos Benchmarks



"Quando uma métrica vira um objetivo, ela deixa de ser uma boa métrica."

— Adaptação da Lei de Goodhart

Modelos podem:

- Memorizar padrões do MMLU durante o pré-treino
- Ser fine-tuned especificamente em questões do benchmark
- Otimizar temperatura e formato para maximizar BLEU

Exemplo real — GSM8K:


- Modelos com MMLU alto falham em variações simples com números diferentes
- Indica memorização, não raciocínio genuíno

Bom benchmark $\neq$ bom desempenho real



Conclusão: Nenhum benchmark sozinho é suficiente. Use múltiplos + avaliação no seu domínio específico.

Take-home Message



1. Sem métrica universal

Escolha a métrica certa para o seu contexto de uso específico.

2. LLM-as-a-Judge

Poderoso, mas com vieses. Valide com humanos, use temp=0 e versione prompts.

3. Métricas Clássicas

BLEU/ROUGE são limitadas. Prefira BERTScore ou similar semântico para geração livre.

4. Negócio ≠ Opcional

Custo (tokens × preço) e latência são críticos. Estime antes de ir para produção.

5. API vs Local

Dados sensíveis ou escala sugerem local. Q4_K_M é uma base sólida para quantização.

6. Dataset Real


Benchmarks genéricos enganam. Crie sua própria avaliação com casos reais de uso.



Conclusão Final: A melhor avaliação é aquela que simula o comportamento real do seu usuário final.



UNICAMP



Avaliação I

Prof. Dr. André Gomes Regino
regino@unicamp.br