




UNICAMP



# Raciocínio em Agentes LLMs

Prof. Dr. Julio Cesar dos Reis  
dosreis@unicamp.br

# Agenda

- ❑ Contexto e Definição
- ❑ Técnicas de Reasoning
- ❑ Desafios

# Motivação

- ❑ Um modelo pode produzir respostas **rápidas** e **convincentes**
- ❑ Contudo, tarefas complexas exigem combinar informações, considerar regras e verificar se a conclusão realmente é sustentada pelos dados.


# Motivação

“Um aluno precisa ter média mínima 6, frequência mínima de 75% e nenhuma pendência acadêmica para ser aprovado.”

{

“média”: 7,  
“frequência”: 82%,  
“pendências”:  
informação indisponível,

}



“O aluno cumpriu os requisitos de  
média e frequência, logo, foi  
aprovado”

A resposta parece coerente, porém, **ignora regras, não chama ferramentas, não verifica** a validade da resposta, ou seja, não há **REASONING!**

# Reasoning

- ❑ É uma capacidade cognitiva

# Reasoning em Agentes

**Processo de transformar informações em decisões.**

**Envolve:**

- inferir conclusões
- aplicar regras
- comparar alternativas
- lidar com incertezas
- verificar hipóteses



# Reasoning

- ❑ Processo de **construir**, **comparar** e **verificar** conclusões a partir de informações disponíveis, restrições e evidências.
- ❑ Um modelo pode produzir uma resposta imediatamente, mas isso não significa que tenha analisado corretamente o problema.

# Tarefa exige Reasoning quando

- ❑ Há múltiplas informações para combinar
- ❑ Existem regras ou restrições
- ❑ Há ambiguidade
- ❑ É preciso comparar alternativas
- ❑ A resposta precisa ser verificada.



# Raciocínio Dedutivo

Estrutura Básica

**Regra**



**Conclusão**

Premissa Geral (Regra)

Todos os alunos com média  $> 6$  são aprovados.

Premissa Particular (Fato)

João possui média 7.

**Conclusão**

**Logo: João pode ser aprovado.**

# Raciocínio Indutivo

❑ Observações → padrão

# Raciocínio Abductivo

- ❑ Evidência → hipótese mais provável

# Raciocínio Analógico

- ❑ Resolver usando casos semelhantes.

# Reasoning ainda não é trivial com LLMs

- ❑ não executam lógica formal
- ❑ podem inventar etapas intermediárias
- ❑ sofrem propagação de erro
- ❑ possuem contexto limitado
- ❑ Resultado:
  - ❑ Mais raciocínio  $\neq$  mais correção.

# Reasoning diferente de Conhecimento

- ❑ Saber não é Raciocinar
- ❑ Pergunta: "Qual a capital da França?" → conhecimento
- ❑ Pergunta: "Se um trem sai de A às 8h..." → reasoning
- ❑ LLMs podem saber fatos sem conseguir combiná-los corretamente.

# Técnicas de Reasoning

- ❑ Técnicas de reasoning ajudam o modelo a organizar o raciocínio
- ❑ Explorar alternativas, usar exemplos e revisar conclusões antes de responder.

# Técnicas de Reasoning

- ❑ Iremos aprofundar:
  - ❑ Few-shot [2]
  - ❑ Chain-of-Thought [5]
  - ❑ Self-ask [7]
  - ❑ Self-Consistency [3]
  - ❑ ReAct [1]
  - ❑ Least-to-Most [4]
  - ❑ Tree of Thoughts [6]



# Exemplo

“Um aluno precisa ter média mínima 6, frequência mínima de 75% e nenhuma pendência acadêmica para ser aprovado.

Ele possui média 7, frequência de 82%, mas o sistema ainda não informa se existem pendências.

***O aluno pode ser aprovado?”***

**Few-Shot**

# Few-Shot

- ❑ Apresenta alguns exemplos resolvidos antes do novo caso.
- ❑ O modelo identifica o padrão
- ❑ Aplica a mesma lógica ao problema atual.

# Few-Shot Prompt

**Instrução:** “Classifique o aluno como aprovado ou reprovado.”

## Exemplo 1

Média: 7

Frequência: 80%

Pendências: nenhuma

Resposta esperada:

**aprovado**

## Exemplo 2

Média: 5

Frequência: 82%

Pendências: nenhuma

Resposta esperada:

**reprovado**

## Agora analise:

Média: 7

Frequência: 82%

Pendências: nenhuma

Resposta do Modelo:

**{sua resposta}**

# Chain-of-Thought

# Chain-of-Thought (CoT)

- ❑ Raciocínio em Cadeia
- ❑ Orienta o modelo a dividir o problema em etapas
- ❑ Verifica cada requisito antes de apresentar a conclusão.

“O aluno possui média 7, frequência de 82% e nenhuma pendência, logo, cumpre todas as regras e está **aprovado**”

# Chain-of-Thought (CoT)

“O aluno possui média 7, frequência de 82% e nenhuma pendência, logo, cumpre todas as regras e está **aprovado**”

# Chain-of-Thought (CoT) – Prompt

**Instrução Geral:** “Analise o caso verificando separadamente cada requisito.”

## 1. Critérios

Média Mínima:

**6.0**

Frequência Mínima:

**75%**

Pendências Acadêmicas:

**Nenhuma**

## 2. Input (Aluno)

Média:

**{media}**

Frequência:

**{frequencia}**

Pendências:

**{pendencias}**

## 3. Formato de Saída

1. Verificação da média


2. Verificação da frequência

3. Verificação de pendências

**4. Conclusão final**



# “Let’s think step by step”



falta de acesso ao mundo externo ou incapacidade de atualizar seu conhecimento pode levar a problemas como alucinação de fatos e propagação de erros.

**Self-ask**

# Self-Ask

## Direct Prompting

GPT-3

Question: Who lived longer, Theodor Haecker or Harry Vaughan Watkins?

Answer: Harry Vaughan Watkins.

Question: Who was president of the U.S. when superconductivity was discovered?

Answer: Franklin D. Roosevelt



## Chain of Thought

GPT-3

Question: Who lived longer, Theodor Haecker or Harry Vaughan Watkins?

Answer: Theodor Haecker was 65 years old when he died. Harry Vaughan Watkins was 69 years old when he died.

So the final answer (the name of the person) is: Harry Vaughan Watkins.

Question: Who was president of the U.S. when superconductivity was discovered?

Answer: Superconductivity was discovered in 1911 by Heike Kamerlingh Onnes. Woodrow Wilson was president of the United States from 1913 to 1921. So the final answer (the name of the president) is: Woodrow Wilson.



# Self-Ask

## Direct Prompting

GPT-3

Question: Who lived longer, Theodor Haecker or Harry Vaughan Watkins?

Answer: Harry Vaughan Watkins.

Question: Who was president of the U.S. when superconductivity was discovered?

Answer: Franklin D. Roosevelt



## Chain of Thought

GPT-3

Question: Who lived longer, Theodor Haecker or Harry Vaughan Watkins?

Answer: Theodor Haecker was 65 years old when he died. Harry Vaughan Watkins was 69 years old when he died.

So the final answer (the name of the person) is: Harry Vaughan Watkins.

Question: Who was president of the U.S. when superconductivity was discovered?

Answer: Superconductivity was discovered in 1911 by Heike Kamerlingh Onnes. Woodrow Wilson was president of the United States from 1913 to 1921. So the final answer (the name of the president) is: Woodrow Wilson.



## Self-Ask

GPT-3

Question: Who lived longer, Theodor Haecker or Harry Vaughan Watkins?

Are follow up questions needed here: Yes.

Follow up: How old was Theodor Haecker when he died?

Intermediate answer: Theodor Haecker was 65 years old when he died.

Follow up: How old was Harry Vaughan Watkins when he died?

Intermediate answer: Harry Vaughan Watkins was 69 years old when he died.

So the final answer is: Harry Vaughan Watkins

Question: Who was president of the U.S. when superconductivity was discovered?

Are follow up questions needed here: Yes.

Follow up: When was superconductivity discovered?

Intermediate answer: Superconductivity was discovered in 1911.

Follow up: Who was president of the U.S. in 1911?

Intermediate answer: William Howard Taft.

So the final answer is: William Howard Taft.



sequência de perguntas intermediárias e acompanhamentos subsequentes

**caracterizado pelo padrão**

“pergunta →

perguntas de acompanhamento →

resposta intermediária →

perguntas de acompanhamento →

resposta intermediária →

... → resposta final”

**Self-Consistency**

# Self-Consistency

- ❑ Gera várias soluções para o mesmo problema
- ❑ Seleciona a conclusão que aparece com maior consistência entre os diferentes caminhos

# Self-Consistency

## Critérios (Regras)

### Requisitos para aprovação:

- Média mínima: **6**
- Frequência mínima: **75%**
- Nenhuma pendência acadêmica

## Dados de Entrada

### Informações do estudante:

- Média obtida: **7**
- Frequência registrada: **82%**
- Pendências: **Nenhuma**

## Self-Consistency

### Instruções de execução:


1. Resolva o caso de **três formas independentes**.
2. Compare as conclusões geradas por cada caminho.
3. Apresente a **resposta mais consistente** (maioria).

**ReAct**



# ReAct (*Reasoning + Acting*)


- ❑ Abordagem que combina raciocínio e ação em ciclos iterativos
- ❑ Permite que agentes LLM ajustem dinamicamente suas estratégias com base em interações contínuas com o ambiente.



# ReAct

- ❑ Combina **raciocínio, ação e observação** em ciclos.
- ❑ O agente **pensa** sobre o problema
- ❑ Decide se **precisa** usar uma ferramenta
- ❑ **Observa** o resultado e
- ❑ **Atualiza** sua próxima decisão.

# ReAct



# ReAct – Exemplo

**Reasoning:** A média e a frequência atendem aos requisitos, mas falta verificar se existem pendências.

**Action:** `consultar_pendencias_aluno()`

**Observation:** O aluno não possui pendências acadêmicas.

**Reasoning:** Todos os requisitos foram atendidos.

**Resposta:** O aluno pode ser aprovado.

# ReAct – Características

- ❑ **Ciclo Iterativo:** O agente alterna entre raciocinar sobre o problema e executar ações, ajustando continuamente sua abordagem.
- ❑ **Adaptação Dinâmica:** Permite que o agente responda a novas informações ou mudanças no contexto de maneira flexível.
  - ❑ executar raciocínio dinâmico para criar, manter e ajustar planos de atuação
- ❑ **Integração de Informações Externas:** O agente pode buscar e incorporar informações adicionais durante o processo de resolução de problemas.


# LLMs Agents – ReAct

- Combinar RACIOCÍNIO e AÇÃO




# LLMs Agents – ReAct

## ❏ Combinar RACIOCÍNIO e AÇÃO



# LLMs Agents – ReAct

## ❏ Combina RACIOCÍNIO e AÇÃO





# ReAct Prompting

- Especificar a Tarefa
  - Sua geração deve ter o seguinte formato (saída do LLM):
    - **Thought:** analisar a observação e informar a ação.
      - gerar traços de raciocínio verbal
    - **Action:** sua ação
      - gerar ações para uma tarefa.
      - permite interagir e coletar informações de fontes externas, como bases de conhecimento ou ambientes.
  - Observação = resposta do ambiente (resultado da ação)  
pode repetir N vezes

# ReAct Prompting Template

Answer the following questions as best you can. You have access to the following tools:

`{tools}`

Use the following format:

Question: the input question you must answer

Thought: you should always think about what to do

Action: the action to take, should be one of [`{tool_names}`]

Action Input: the input to the action

Observation: the result of the action

... (this Thought/Action/Action Input/Observation can repeat N times)

Thought: I now know the final answer

Final Answer: the final answer to the original input question

Begin!

Question: `{input}`

Thought:`{agent_scratchpad}`

# Vantagens do Planejamento *ReAct*

- ❑ **Adaptabilidade:** O agente ajusta suas ações com base em novas informações ou mudanças no ambiente.
- ❑ **Eficiência:** Combina raciocínio e ação para resolver problemas de forma mais eficaz.
- ❑ **Redução de Erros:** A iteração contínua permite a correção de erros em tempo real.
- ❑ **Melhoria Contínua:** O agente aprende e aprimora suas estratégias através de ciclos iterativos.

**Least-to-Most**

# Least-to-Most

- ❑ Divide um problema complexo em questões menores.
- ❑ Cada resposta obtida ajuda a resolver a etapa seguinte até chegar à conclusão final.

# Least-to-Most – Prompting

## Contexto & Requisitos

### Crítérios de Aprovação:

- Média mínima: 6
- Frequência mínima: 75%
- Nenhuma pendência acadêmica

### Dados de Entrada (Input):

- Média: 7
- Frequência: 82%
- Pendências: nenhuma

## Decomposição do Problema

*"Divida o problema em questões menores:"*

1. A média atende ao requisito?
2. A frequência atende ao requisito?
3. Existem pendências acadêmicas?
4. **Considerando as respostas anteriores, o aluno foi aprovado?**

# Tree of Thoughts

# Tree of Thoughts (ToT)


- ❑ Explora diferentes caminhos de raciocínio
- ❑ Avalia cada alternativa
- ❑ Seleciona a mais adequada antes de responder.
- ❑ Diferentemente do CoT, ele não segue apenas uma sequência linear.



# Tree of Thoughts (ToT)

- ❑ A exploração começa na raiz do problema.
- ❑ Em cada nível, o modelo gera alternativas
- ❑ Avalia quais são mais promissoras
- ❑ Expande apenas os caminhos selecionados.
- ❑ Faz busca em largura (BFS), ou em profundidade (DFS)
- ❑ Retorna quando não produz uma solução adequada.

# Tree of Thoughts (ToT)



# Tree of Thoughts (ToT)

## Desafio & Contexto

“Um aluno precisa ter:

- média mínima 6;
- frequência mínima 75%;
- nenhuma pendência acadêmica.


### Dados:

- média: 7;
- frequência: 82%;
- pendências: informação indisponível.

### Explore três possibilidades:

1. o aluno não possui pendências;
2. o aluno possui pendências;

Avalie cada possibilidade e indique qual conclusão pode ser sustentada pelos dados atuais.”



# Comparando as Técnicas

| Técnica          | Ideia                  | Quando usar         |
|------------------|------------------------|---------------------|
| Few-Shot         | Aprender padrão        | Classificação       |
| CoT              | Resolver passo a passo | Regras              |
| Self-Ask         | Quebrar perguntas      | Multi-hop           |
| Self-Consistency | Votar entre soluções   | Reduzir erro        |
| Least-to-Most    | Subproblemas           | Problemas complexos |
| ToT              | Explorar alternativas  | Busca               |
| ReAct            | Pensar + agir          | Agentes             |

# Reasoning vs. Planning vs. Tools


- ❑ Reasoning e planning são capacidades diferentes, embora possam trabalhar juntas em um agente.

| Capacidade        | Pergunta central                       | Resultado                           |
|-------------------|----------------------------------------|-------------------------------------|
| Reasoning         | O que posso concluir?                  | Conclusão, decisão ou hipótese      |
| Planning          | O que devo fazer e em que ordem?       | Plano de ações                      |
| Acting / Tool Use | Qual ação ou ferramenta devo executar? | Resultado da execução da ferramenta |


# Reasoning vs Planning vs Tools



# Reasoning vs Planning vs Tools




# Reasoning vs Planning vs Tools





# Reasoning vs Planning vs Tools



# Desafios

- ❑ Erro em etapas intermediárias
  - ❑ Um erro inicial pode contaminar toda a conclusão
- ❑ Custo e latência
  - ❑ Mais passos, caminhos e chamadas aumentam o consumo

# Desafios

- ❑ Loops excessivos
  - ❑ O agente pode continuar analisando sem melhorar
- ❑ Escolha inadequada da técnica
  - ❑ Uma abordagem complexa pode ser desnecessária para tarefas simples

# Reasoning depende de Memória

Para raciocinar, o agente precisa de:

## 1 Lembrar objetivos


Manter o foco no resultado que deve ser alcançado.

## 2 Lembrar estados anteriores

Acompanhar o histórico de ações e o progresso do plano.

## 3 Recuperar evidências relevantes

Acessar os fatos e conhecimentos necessários para a tomada de decisão.



# Síntese

- ❑ Reasoning organiza a construção e a verificação de conclusões
- ❑ Diferentes técnicas estruturam o processo de resolução
- ❑ CoT organiza etapas; ToT explora alternativas
- ❑ ReAct integra raciocínio, ação e observação
- ❑ Reasoning e planning são distintos, mas podem atuar juntos
- ❑ Mais etapas não garantem melhor resultado
- ❑ Verificação, custo e condição de parada são essenciais

# Referências

- [1] BROWN, T. B. et al. Language Models are Few-Shot Learners. NeurIPS, 2020.
- [2] WEI, J. et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. NeurIPS, 2022.
- [3] WANG, X. et al. Self-Consistency Improves Chain of Thought Reasoning in Language Models. ICLR, 2023.
- [4] ZHOU, D. et al. Least-to-Most Prompting Enables Complex Reasoning in Large Language Models. ICLR, 2023.
- [5] YAO, S. et al. Tree of Thoughts: Deliberate Problem Solving with Large Language Models. NeurIPS, 2023.
- [6] YAO, S. et al. ReAct: Synergizing Reasoning and Acting in Language Models. ICLR, 2023.
- [7] <https://arxiv.org/abs/2210.03350>