




UNICAMP



Comunicação em Sistemas Multiagentes


Prof. Dr. Julio Cesar dos Reis
dosreis@unicamp.br

Agenda

- ❑ Motivação
- ❑ Orquestração de sistemas multiagentes conversacionais
- ❑ Conversação em sistemas baseados em LLM
- ❑ Desafios em sistemas multiagentes conversacionais

Sistemas monoagentes

- ❑ Sistemas baseados em um único Grande Modelo de Linguagem (LLM) são eficientes em certos tipos de problemas:
 - resolução de questões
 - escrita criativa
 - geração de código



Sistemas monoagentes

- ❑ Esses sistemas são propensos à falhas como:
 - vieses;
 - interpretabilidade;
 - confiança cega;

Problema

- ❑ Um agente isolado consegue resolver diversas tarefas

Problema

- ❑ Um agente isolado consegue resolver diversas tarefas
- ❑ Entretanto, tarefas complexas exigem:
 - diferentes especializações;
 - divisão de trabalho;
 - revisão entre especialistas;
 - negociação;
 - tomada de decisão coletiva.

Exemplo

- ❑ Imagine um agente responsável por construir um plano de viagem.
- ❑ Outros agentes:
 - pesquisam voos;
 - pesquisam hotéis;
 - verificam clima;
 - calculam custos;
 - revisam restrições.

Sistemas multiagentes

- ❑ Humanos raramente são capazes de fazer tarefas complexos sozinhos
- ❑ É comum que se peça ajuda a outros com maior qualificação
- ❑ Interações e trocas de experiências auxiliam na resolução de tarefas
- ❑ Podemos replicar essas interações para sistemas multiagentes, especialmente os que tentam resolver tarefas conversacionais

Comunicação

- ❑ A comunicação torna-se o mecanismo que integra essas competências.
- ❑ Sem comunicação, cada um trabalha isoladamente.
- ❑ Com comunicação adequada, surge um sistema cooperativo.

Comunicação em Sistemas Multiagentes

- ❑ Em sistemas multiagentes a comunicação é fundamental para a coordenação e execução de tarefas.
- ❑ A comunicação é um dos aspectos mais relevantes na especificação dos agentes.
- ❑ Diferentes arquiteturas utilizam diferentes métodos de comunicação.

Comunicação x Coordenação x Colaboração




- ❏ Troca de informações.
- ❏ Exemplo: "Encontrei um hotel."

Aspectos Principais na Comunicação


1. Como os agentes trocam informações?
2. O que acontece quando agentes possuem esquemas de dados diferentes?
3. Os agentes compartilham o histórico completo ou apenas os resultados finais?

Comunicação x Coordenação x Colaboração



- ❑ Organização das ações.
- ❑ Exemplo: "Primeiro reserve o voo. Depois o hotel."

Comunicação x Coordenação x Colaboração



- ❑ Agentes trabalham conjuntamente para resolver um objetivo.
- ❑ Exemplo: Planejar toda uma viagem.¹⁴

Orquestração de sistemas multiagentes

- ❑ **Orquestração** é o processo de sistematização das interações entre os agentes

Orquestração de sistemas multiagentes

- ❑ De forma análoga ao mundo real, as conversas entre agentes precisam ser frutíferas para que haja algum aprendizado ou avanço na tarefa
- ❑ Os mesmos desafios surgem nas interações multiagentes
 - quantidade de agentes
 - ordem de fala
 - quem consegue falar com quem
 - tomada de decisão

Agentes Moderadores


- ❑ tendem a ser neutros
- ❑ delegam tarefas para os participantes
- ❑ coordenam o processo de conversa

Agentes Participantes – Especialistas

- ❑ contribuem para a resolução da tarefa
- ❑ possuem personalidades e crenças únicas
- ❑ podem usar ferramentas específicas

Orquestração multiagente

- ❑ As características de um agente moderador podem ser implementadas de outras formas
- ❑ Ordem e direção da conversa
- ❑ Tomada de decisão




Orquestração multiagente

- ❑ Comunicação não significa liberdade total
- ❑ Um modelo de comunicação orquestrado define:
 - quem fala;
 - quando fala;
 - para quem fala;
 - o que pode ser enviado.
- ❑ Esse conjunto forma um paradigma de comunicação


Conversação entre agentes

- ❑ Havendo dois ou mais agentes no sistema, como esquematizar uma conversa?
- ❑ A ordem é importante?
 - Sim! Um agente que avalia um item precisa que este seja previamente criado







Conversação entre agentes

- ❑ Havendo dois ou mais agentes no sistema, como esquematizar uma conversa?
- ❑ A ordem é importante?
 - Sim! Um agente que avalia um item precisa que este seja previamente criado
- ❑ A direção é importante?
 - Depende. O agente criador pode usar feedback do avaliador para adaptar o item criado



Paradigmas de comunicação

- ❑ Yin *et al.* (2023) propuseram quatro paradigmas de conversação entre LLMs
- ❑ Os paradigmas foram baseados em topologias de rede
- ❑ Cada paradigma implica em quais modelos têm acesso ao raciocínio dos demais em um dado momento



Paradigmas de comunicação – formalização

- ❑ A formalização de uma comunicação pode ser dada por

$$\{M\} = \{m_1, m_2, \dots, m_n\}$$

Conjunto de LLMs

Raciocínio (r) e resposta (a) de um modelo i
em dado intervalo j

baseado em  $(r_K^{(j-1)}, a_K^{(j-1)})$

Par (r, a) onde K é o subconjunto de LLMs
que o modelo i pode receber mensagens

Paradigmas de comunicação

❏ *Memory*

❏ *Report*


❏ *Relay*

❏ *Debate*

Memory


Memory

- ❑ Os pares (r, a) são armazenados em um *logbook*
Raciocínio (r) e a resposta (a) de um modelo i em um dado intervalo j
- ❑ O *logbook* é visível por qualquer modelo a qualquer momento



Memory

- ❑ Os pares (r, a) são armazenados em um *logbook*
Raciocínio (r) e a resposta (a) de um modelo i em um dado intervalo j
- ❑ O *logbook* é visível por qualquer modelo a qualquer momento
- ❑ Comunicação facilitada, pois qualquer modelo pode se comunicar com os demais
- ❑ Custos elevados de armazenamento do *logbook*



Report

Report

- ❑ Um nó é designado como o central (e.g., **A**)
- ❑ O nó central pode se comunicar com os demais nós




Report

- ❑ Um nó é designado como o central (e.g., **A**)
- ❑ O nó central pode se comunicar com os demais nós
- ❑ No entanto, todos os outros nós podem apenas se comunicar com o nó central




Report

- ❑ Um nó é designado como o central (e.g., **A**)
- ❑ O nó central pode se comunicar com os demais nós
- ❑ No entanto, todos os outros nós podem apenas se comunicar com o nó central
- ❑ Implica em alta demanda de processamento do nó central, pois ele irá agir como um *hub* de comunicação
- ❑ Um exemplo de nó central pode ser o moderador



Report - Exemplo com *LangGraph*


- ❑ Conjunto de quatro agentes:
 - um moderador
 - três participantes (A, B, C)
- ❑ *next_agent_node* é um nó de processamento que decide o próximo agente
- ❑ Moderador decide quando encerrar a conversa



Relay

Relay

- ❑ Todos os nós são ordenados segundo um critério
- ❑ Um dado nó só pode receber mensagem do seu anterior imediato e enviar mensagem para seu posterior imediato




Relay

	A	B	C
A	☒	☒	☐
B	☐	☒	☒
C	☒	☐	☒

Neighbor Visible

Relay

- ❑ Todos os nós são ordenados segundo um critério
- ❑ Um dado nó só pode receber mensagem do seu anterior imediato e enviar mensagem para seu posterior imediato
- ❑ O ciclo de informação é distribuído, porém incremental




Relay

	A	B	C
A	☒	☒	☐
B	☐	☒	☒
C	☒	☐	☒

Neighbor Visible

Relay

- ❑ Todos os nós são ordenados segundo um critério
- ❑ Um dado nó só pode receber mensagem do seu anterior imediato e enviar mensagem para seu posterior imediato
- ❑ O ciclo de informação é distribuído, porém incremental
- ❑ Reduz o processamento individual dos nós, mas implica em maior tempo de propagação de mensagem




Relay

	A	B	C
A	☒	☒	☐
B	☐	☒	☒
C	☒	☐	☒

Neighbor Visible 37

Relay - Exemplo com *LangGraph*


- ❑ Mesmo conjunto anterior
- ❑ Participantes não retornam diretamente para o moderador ao agirem
- ❑ Moderador decide quando encerrar a conversa



Debate


Debate

- ❑ Paradigma baseado em árvores computacionais
- ❑ A informação é gerada nas folhas e propagada para a raiz



Debate

- ❑ Paradigma baseado em árvores computacionais
- ❑ A informação é gerada nas folhas e propagada para a raiz
- ❑ Apenas os nós-folha podem comunicar-se entre si




Debate			
	A	B	C
A	☒	☒	☒
B	☐	☒	☒
C	☐	☒	☒

Peers Visible

Debate

- ❑ Paradigma baseado em árvores computacionais
- ❑ A informação é gerada nas folhas e propagada para a raiz
- ❑ Apenas os nós-folha podem comunicar-se entre si
- ❑ Os nós-pai apenas recebem e propagam as mensagens
- ❑ Balanceia a carga de processamento dos nós com o custo de propagação das mensagens



Debate			
	A	B	C
A	☒	☒	☒
B	☐	☒	☒
C	☐	☒	☒

Peers Visible			
	A	B	C
A	☒	☒	☒
B	☐	☒	☒
C	☐	☒	☒

Critérios de parada

- ❑ Apenas ter um paradigma de conversa estabelecendo ordem e visibilidade das mensagens não é suficiente
- ❑ Assim como no mundo real, a discussão precisa terminar e ter seus resultados consolidados
- ❑ Podemos nos basear na saída de um modelo para estabelecer critérios:
 - Término por Saída Consistente
 - Término pelo Consenso da Maioria

Critérios de parada – Saída Consistente

- ❑ Verifica se em um dado momento, a saída de um modelo foi igual à saída do modelo de um momento anterior
- ❑ Quando isso ocorre, a conversa se encerra
- ❑ A saída do modelo atual é retornada como resposta da tarefa
- ❑ A comparação precisa ser feita a cada iteração, independente do paradigma
- ❑ Mas, e se essa condição nunca for alcançada?

Critérios de parada – Consenso da Maioria

- ❑ Neste critério, opta-se por reconhecer que a maioria dos modelos apresentou a mesma resposta em um dado intervalo da comunicação
- ❑ O intervalo pode ser definido como assim que tal condição for estabelecida ou após um número fixo de interações
- ❑ E se não houver consenso após este número fixo?
 - retornar a mensagem do último modelo como resposta
 - retornar uma mensagem de que não houve consenso, indicando erro

Integração com sistemas multiagentes

- ❑ Os paradigmas e critérios foram elaborados pensando em sistemas baseados em LLM
- ❑ Nada impede que os paradigmas sejam aplicados a sistemas multiagentes:
 - os nós de cada paradigma podem ser interpretados como agentes
 - presença ou não de um moderador
 - critérios de parada são análogos

Desafios

Desafios

- ❑ Análise comparativa entre sistemas mono e multiagente
- ❑ Conjuntos de tarefas conversacionais de complexidade distintas:
 - Resumos, geração de paráfrases, traduções
 - Extração de conteúdo e *benchmarks* de Q&A
- ❑ Sistemas monoagentes se destacam em tarefas simples
- ❑ A discussão favorece a resolução de tarefas complexas

Desafios

- ❏ Três desafios decorrentes de ações conversacionais:
 - *problem drift*
 - *alignment collapse*
 - *monopolization*

Problem Drift

- ❑ Para obter um consenso, os agentes tendem a conversar por maiores períodos
- ❑ Ao mesmo tempo que isso aumenta o poder de raciocínio, nuances específicas da tarefa a ser resolvida podem ser esquecidas
- ❑ A perda de desempenho por conta desse esquecimento é caracterizada como *problem drift*
- ❑ Possíveis causas:
 - natureza análoga do problema em agentes únicos (*task drift*)
 - propostas de múltiplas soluções para uma mesma tarefa

Alignment Collapse

- ❑ Prolongados períodos de discussão podem fazer com que os agentes explorem cada vez mais as ideias para resolver a tarefa
- ❑ No entanto, uma ideia inicial discutida já poderia ter sido suficiente, mas acaba sendo descartada
- ❑ Quando isso acontece, o desempenho é prejudicado, sendo caracterizado como *alignment collapse*
- ❑ O fenômeno é importante, pois pode resultar em questões de toxicidade e segurança em IA

Monopolization

- ❑ Ocorre quando um agente passa a dar respostas longas para influenciar os demais
- ❑ Impacta no processo de tomada de decisão
- ❑ O comportamento é mais propício de acontecer em agentes centrais, se não tomar o devido cuidado
- ❑ A “personalidade” de um agente também impacta na possibilidade dele tender a ser “manipulador” (monopolizador da comunicação)

A Comunicação define o Sucesso do Sistema Multiagente

- ❑ Sistemas multiagentes bem projetados otimizam a comunicação e melhoram o desempenho geral
- ❑ A comunicação entre agentes é um fator crítico para a eficiência e efetividade do sistema
- ❑ Diferentes abordagens têm vantagens e desafios específicos
- ❑ O melhor método depende do caso de uso e dos requisitos do sistema
- ❑ A tendência é a integração de técnicas híbridas para maior flexibilidade e escalabilidade

Síntese


- ❑ Sistemas multiagentes distribuem responsabilidades entre agentes especializados
- ❑ A arquitetura define como os agentes se organizam, comunicam e coordenam suas ações
- ❑ A comunicação permite compartilhar informações, delegar tarefas e sincronizar decisões
- ❑ Diferentes paradigmas de comunicação determinam os modos de comunicação entre agentes

Bibliografia

- ❑ Yin, Z., Sun, Q., Chang, C., Guo, Q., Dai, J., Huang, X. J., & Qiu, X. (2023). Exchange-of-thought: Enhancing large language model capabilities through cross-model communication. In Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (pp. 15135-15153).
- ❑ Becker, J. (2024). Multi-agent large language models for conversational task-solving. arXiv preprint arXiv:2410.22932.
- ❑ Wang, Y., Pan, Y., Zhao, Q., Deng, Y., Su, Z., Du, L., & Luan, T. H. (2024). Large Model Agents: State-of-the-Art, Cooperation Paradigms, Security and Privacy, and Future Trends. arXiv preprint arXiv:2409.14457.


Memory – Custos de comunicação

- ❑ Assuma que existam n nós
- ❑ Com o *logbook*, todos os nós recebem mensagens de todos os demais da interação prévia
- ❑ Sendo assim, o volume de comunicação é n^2



Report – Custos de comunicação

- Assuma que existam n nós
- O nó central processa n mensagens a cada rodada
- Os demais $n - 1$ nós processam apenas 2
- Sendo assim, o volume de comunicação é $3n - 2$




Report			
	A	B	C
A	☒	☒	☒
B	☒	☒	☐
C	☒	☐	☒

Central Visible

Relay – Custos de comunicação

- Assuma que existam n nós
- A cada instante, um nó recebe mensagem de si mesmo e do nó anterior imediato
- Isso resulta em um volume de comunicação de $2n$
- Na transmissão, o nó i recebe mensagem do $i - 1$, mas para este nó i receber a mensagem do $i + 1$, são necessárias $n - 1$ transmissões
- Isso resulta numa taxa média de propagação de mensagens de $(n - 1) / 2$




Relay

	A	B	C
A	☒	☒	☐
B	☐	☒	☒
C	☒	☐	☒

Neighbor Visible

Debate – Custos de comunicação

- ❑ Assuma que os n nós formam uma árvore binária de altura $h = \lceil \log_2(n + 1) \rceil$
- ❑ Cada par de nós-filho tem volume de comunicação igual a 2, enquanto o nó-pai tem volume 3
 - Uma subárvore de dois filhos e um pai tem volume 7
 - Uma árvore binária tem $2^{(h-1)} - 1$ subárvores dessas
- ❑ Se n for par, o volume total é de $7(n - 1) / 2$
- ❑ A propagação de mensagens entre dois nós requer até $2(h - 1)$ transmissões



Debate

	A	B	C
A	☒	☒	☒
B	☐	☒	☒
C	☐	☒	☒

Peers Visible