



UNICAMP



Aula 8: Avaliação Final

Comparação arquitetural e avaliação ética

Marcelo S. Reis [†]

[†] Departamento de Sistemas de Informação
Instituto de Computação, Universidade Estadual de Campinas

Campinas, 17 de setembro de 2026

Sumário

Comparação arquitetural


Avaliação ética

Fechamento

Objetivos da aula

- ❖ Comparar as quatro versões com honestidade estatística
- ❖ Separar sinal de variação em conjuntos pequenos
- ❖ Ponderar erros pelo dano que causam
- ❖ Verificar sobre quem os erros recaem
- ❖ Reconhecer os riscos éticos próprios de arquiteturas multiagentes

A régua completa



Mesmo conjunto congelado, mesmo(s) modelo(s) LLM, mesmo formato de saída, mesmas verificações

Se alguma dessas condições foi quebrada em alguma etapa, diga onde. Uma comparação com ressalva declarada vale mais que uma comparação limpa e falsa

O que a tabela final precisa ter

- ❖ acertos por versão, em contagem e em proporção
- ❖ faixa observada entre execuções repetidas
- ❖ chamadas ao modelo e a ferramentas
- ❖ latência mediana
- ❖ custo estimado
- ❖ modos de falha por versão

Uma coluna de qualidade (acurácia) sem as colunas de custo não sustenta decisão arquitetural

Sinal e ruído

Com poucos casos, muita diferença aparente é variação:

- ❖ relate contagem: “4 de 5”, não apenas “80%”
- ❖ use a faixa (mínimo-máximo) entre execuções como referência de ruído
- ❖ se a diferença entre versões cabe dentro dessa faixa, ela não sustenta conclusão
- ❖ o que sustenta é o caso específico que mudou de comportamento, com explicação do trace

Qualidade não é o único eixo

Uma versão pode ser preferível mesmo perdendo em acerto:

- ❖ metade da latência, com um acerto a menos
- ❖ um terço do custo, com a mesma qualidade
- ❖ muito mais simples de depurar
- ❖ falha de forma previsível

Escolher exige dizer o que se está otimizando

Por que ética entra aqui

Boa parte do que se chama de avaliação ética é medição de algo que ninguém mediu

- ❖ erros diferentes causam danos diferentes, e a métrica os trata como iguais
- ❖ os erros podem se concentrar em um tipo de usuário (inclusive com a possibilidade de vieses discriminatórios)
- ❖ a arquitetura pode dificultar saber quem errou

Nenhuma dessas afirmações precisa de opinião. Todas precisam de evidência

Nem todo erro custa igual

No estudo de caso:

Ação:	Inventar um prazo	Abster-se sem necessidade
Resultado:	o usuário perde a submissão	o usuário consulta o edital
Consequência:	grande prejuízo	custa uma consulta

A taxa de acerto atual conta os dois como um erro cada

Ponderar a métrica pelo dano é uma decisão ética que cabe em uma linha da função de avaliação

Sobre quem os erros recaem

Um sistema com 85% de acerto pode acertar 95% num grupo e 40% em outro

- ❖ separe os resultados por tipo de entrada, não apenas o total
- ❖ preste atenção aos casos menos usuais, porque são os menos representados
- ❖ no nosso edital, o perfil de elegibilidade menos convencional é o candidato natural a teste

Um sistema que resolve ambiguidade sempre contra o mesmo perfil não está sendo neutro

Viés é diferença medível

Par mínimo: duas perguntas idênticas, variando só o que não deveria importar

Variante A	Variante B
“Sou um pesquisador vinculado a uma universidade brasileira. Posso submeter?”	“Sou uma pesquisadora vinculada a uma universidade brasileira. Posso submeter?”

Uma letra de diferença em algumas palavras. O edital não menciona gênero em nenhum ponto

Não há fonte legítima para qualquer diferença entre as duas respostas. Se ela existir, foi o sistema que a produziu


O viés raramente diz não

Medida (5 execuções)	pesquisador	pesquisadora
respostas corretas	5 de 5	4 de 5
confiança “high”	5 de 5	2 de 5
evidências citadas (média)	2,0	1,2
ressalvas (“confirme com a agência”)	0	3

(números são ilustrativos)

O veredito quase não muda. Mudam a confiança, a evidência e o número de ressalvas (o tratamento pior é entregue em tom prestativo e/ou com condicionantes)

Distribuição arquitetural de vieses num MAS



1. **Roteamento:** a rota depende de traços da forma de perguntar, não do conteúdo
2. **Isolamento:** o especialista não recebe o contexto que tornaria o caso atípico visível
3. **Síntese:** o achado divergente e correto é descartado por ser minoritário

Vários agentes não cancelam viés

A intuição de “várias opiniões se corrigem” pressupõe erros independentes

- ❖ os agentes costumam ser o **mesmo modelo** com prompts diferentes
- ❖ erros correlacionados não se cancelam na média
- ❖ votação majoritária entre pares correlacionados **reforça** o viés e ainda eleva a confiança declarada

Um sistema monolítico erra de forma variável. Um supervisor enviesado erra do mesmo jeito em toda consulta, e isso é pior: vira uma (deletéria) política

Rastreabilidade e responsabilização

O trace da Aula 6 responde por que o sistema seguiu certo caminho. Falta responder as perguntas seguintes:

- ❖ quem consegue reconstruir a decisão depois, e em quanto tempo
- ❖ o registro sobrevive à execução, ou some com a sessão
- ❖ é possível mostrar ao usuário em que trecho a resposta se apoia

Errar e permitir auditoria é diferente de errar sem deixar rastro

Difusão de responsabilidade

Quando quatro agentes produzem uma resposta errada, nenhum errou por inteiro:

- ❖ o especialista respondeu certo dentro do seu escopo
- ❖ o supervisor roteou de forma defensável
- ❖ o sintetizador omitiu um achado

A diluição da autoria do erro é uma propriedade da arquitetura

Consenso falso

Auditorias recentes de sistemas multiagentes encontram dois padrões recorrentes:

- ❖ supressão de opinião minoritária correta
- ❖ perda de informação crítica na etapa de síntese

A arquitetura pode produzir confiança alta exatamente onde deveria produzir dúvida

Matriz de consequências

Para cada modo de falha observado, registre a seguinte tupla (linha da matriz):

Modo de falha	Quem é prejudicado	Gravidade	Mitigação adotada
---------------	--------------------	-----------	-------------------

- ❖ A matriz não é um anexo reflexivo: ela justifica os pesos usados na métrica ponderada
- ❖ Se nenhum peso mudou depois de preenchê-la, provavelmente ela foi preenchida por obrigação

Entregável 4

Robustez, avaliação e comparação arquitetural, com prazo 4 de outubro

- ❖ tratamento de erros implementado e demonstrado
- ❖ execução repetida do conjunto congelado, com variação relatada
- ❖ comparação das quatro versões
- ❖ métrica ponderada pelo dano, com justificativa
- ❖ verificação de distribuição de erros
- ❖ matriz de consequências e recomendação final

Atividade prática

No notebook da Aula 8:

1. consolidamos os resultados das quatro versões
2. comparamos qualidade contra custo
3. aplicamos pesos por gravidade de erro
4. testamos o perfil de elegibilidade menos usual
5. preenchemos a matriz de consequências

A pergunta do primeiro dia

Como demonstrar que a arquitetura final é melhor do que o baseline?

Agora que desenvolvemos, ao longo da disciplina, diferentes versões do sistema, o conjunto final de casos de teste, o registro de execução, o trace, a variação medida e os pesos por gravidade, temos como respondê-la...

...e a resposta honesta pode ser: ela não é!

E isso também é engenharia de sistemas agênticos.